

Actividad Formativa 01

Teorema del Límite Central

Dany Lopez (dxlopez@ul.cl) - José Luis Pérez (josel.perez@uc.cl)

Contenido


1 Contexto	2
2 Actividad Introductoria	3
2.1 Análisis de un grupo con 40 muestras	3
3 Pregunta d.1)	3
3.1 Análisis considerando las 400 muestras	4
4 Pregunta a	4
5 Pregunta b	7
6 Pregunta c	8
7 Pregunta d	10
8 Pregunta e	10
9 Actividad Aplicada 1: Teorema Límite Central	10
10 Pregunta a	11
11 Pregunta b	12
12 Pregunta c	12
13 Pregunta d	12
14 Pregunta e	13
15 Actividad Aplicada 2: Intervalo de confianza	13

16 Pregunta a	14
17 Pregunta b	15
18 Actividad Aplicada 3 (avanzado): Probabilidad de cobertura	16
19 Pregunta a	17
20 Pregunta b	18

1 Contexto

Suponga que se desarrolla un estudio que busca caracterizar sociodemográficamente a las y los docentes de todas las escuelas del país, incluyendo escuelas públicas, subvencionadas, privadas, y del Servicio Local de Educación Pública (SLEP). En particular, se tiene como objetivo determinar la edad promedio de los docentes que se desempeñan durante el año 2024 en las escuelas del país.

Usaremos los datos de **Cargo Docente** del año 2024 proporcionada por el **Centro de Estudios Mineduc**. Estos datos corresponden a la información censal de todos los docentes del sistema escolar que tienen un cargo en al menos una escuela durante el año 2024.



La cantidad total de docentes con cargo en el sistema escolar equivale a 266,069. La edad promedio de la población de docentes es de $\mu = 42.77$ años, con una desviación estándar de $\sigma = 11.91$ años. En un intento por verificar el rango etario promedio, se seleccionaron 400 muestras aleatorias de tamaño $N = 30$ docentes cada muestra. A partir de estas 400 muestras se construyeron 10 grupos, con cada grupo compuesto por 40 muestras. Puede acceder al listado de muestras para cada grupo en el siguiente link: [ver aquí](#)

Note que los datos que usaremos son los mismos que utilizamos en la primera actividad [ver detalle actividad aquí](#).

2 Actividad Introductoria

2.1 Análisis de un grupo con 40 muestras

- a. Identifique el número de grupo que le fue asignado en la clase 01. Si no estuvo presente en la primera clase, seleccione un grupo con el que desea trabajar. De manera similar a como lo trabajó en la primera clase, calcule el promedio de cada muestra. Puede utilizar Excel, BlueSky Statistics o R para calcular el promedio.
- b. Calcule ahora el promedio de todos los promedios muestrales. Puede utilizar Excel, BlueSky Statistics o R para calcular el promedio.
- c. Con los promedios de cada muestra ahora construya un gráfico de frecuencias. En el mismo gráfico, represente el promedio de todos los promedios (puede hacerlo dentro del gráfico marcando con un punto o una línea la ubicación del promedio).
- d. Una vez que haya graficado, observe el resultado que se obtiene y luego responda las siguientes preguntas:
 1. ¿Qué representa el gráfico?
 2. ¿Entre qué rangos se concentran la mayoría de los promedios de las edades de las muestras?

Nota: Las respuestas de esta sección fueron contestadas en clases. Recomendamos mirar la grabación de la segunda clase del curso que se encuentra en TEAMS para contestarlas.

Solución

3 Pregunta d.1)

Ver solución d.1

El gráfico corresponde a un histograma de frecuencias, utilizado para representar la distribución de un conjunto de datos cuantitativos. A diferencia del gráfico de barras, empleado para variables cualitativas, el histograma utiliza barras contiguas cuya altura indica la frecuencia relativa (o proporción) de observaciones que se encuentran dentro de determinados subintervalos del dominio. Estos subintervalos se disponen de manera ordenada a lo largo del eje horizontal. Para mayores detalles, consulte las siguientes referencias¹:

[1] Field, A. P., Miles, J., & Field, Z. (2012). *Discovering statistics using R*. London; Thousand Oaks, Calif.: Sage. p. 142-144

[2] Mendenhall, W., & Beaver, B. M. (2011). *Introducción a la probabilidad y estadística*

3.1 Análisis considerando las 400 muestras

Ahora incluiremos todas las muestras de todos los grupos, es decir, consideraremos la colección total de 400 muestras de tamaño $N = 30$ cada una. Responda las siguientes preguntas:

- Calcule el promedio de cada una de las muestras.
- Construya un histograma de frecuencias con los 400 promedios muestrales.
- Calcule el promedio de todos los promedios (el gran promedio) y ubíquelo en el gráfico de frecuencia.
- Ahora calcule la desviación estándar de los promedios muestrales $\sigma_{\bar{x}}$.
- Ahora, cuente cuántos promedios muestrales se ubican a $\pm 1\sigma_{\bar{x}}$ en torno al gran promedio. Y ¿Cuántos promedios muestrales se ubican a $\pm 2\sigma_{\bar{x}}$ en torno al gran promedio?

Solución

4 Pregunta a

Ver solución

Por definición, la media se estima por medio de la siguiente expresión:

$$\bar{x} = \frac{\sum_1^n x_i}{n} = \frac{x_1 + x_2 + x_3 + x_4 + \cdots + x_{n-1} + x_n}{n}$$

con x_i la edad del docente i y n el número total de individuos. La expresión anterior significa que debemos sumar todas las edades en una muestra y dividir este resultado por el número total de docentes que forma parte de dicha muestra. Para ilustrar su aplicación, consideremos la muestra m_1 . Dado que la muestra m_1 está compuesta $n = 30$ docentes (lo mismo para todas las demás muestras), entonces la expresión para calcular el promedio queda

¹ Estas referencias se encuentran en Canvas, en la clase 02.

$$\begin{aligned}
 \bar{x}_{m_1} &= \frac{\sum_1^{30} x_i}{30} \\
 &= \frac{x_1 + x_2 + x_3 + x_4 + x_5 + \cdots + x_{26} + x_{27} + x_{28} + x_{29} + x_{30}}{30} \\
 &= \frac{31 + 31 + 57 + 41 + 49 + \cdots + 31 + 42 + 43 + 27 + 54}{30} \\
 &= 42.8
 \end{aligned}$$

Así, la muestra m_1 tiene un promedio $\bar{x}_{m_1} = 42.8$. Usando entonces la misma expresión para el resto de las muestra, en la siguiente tabla se muestran todos los promedios calculados para cada muestra:

5 Pregunta b


💡 Ver solución

El histograma de frecuencias de los promedios de la 400 muestras se muestra a continuación.

```
library(ggplot2)

ggplot(promedio_muestras, aes(x = as.numeric(promedio))) +
  geom_histogram(binwidth=0.6, colour="#56B4E9", fill="skyblue") +
  labs(x="Edad", y= "Frecuencia") +
  ylim(c(0,60)) +
  xlim(c(36,50)) +
  ggtitle("Distribución de promedios muestrales de edades de 400 muestras") +
  theme_bw(base_size = 11) +
  geom_text(geom = "text", label="colour=red,\n fill=skyblue", x=25,y=50,col="black") +
  theme(
    text = element_text(size = 13),
    axis.text.x = element_text(color = "black",angle = 0, hjust = 0.5),
    # text = element_text(size = 15),
    axis.text.y = element_text(color = "black",angle = 0, hjust = 0.5),
    legend.position = "none"
  )
```

Distribución de promedios muestrales de edades d



6 Pregunta c

💡 Ver solución

El promedio de todos los promedios equivale a 42.66 años. A continuación se muestra su ubicación en el histograma construido anteriormente



```
library(ggplot2)

gran_avg <- db %>%
  dplyr::summarise(promedio = mean(edad, na.rm = T))

ggplot(promedio_muestras, aes(x = as.numeric(promedio))) +
  geom_histogram(binwidth=0.6, colour="#56B4E9", fill="skyblue") +
  geom_vline(xintercept = gran_avg$promedio ) +

  labs(x="Edad",y= "Frecuencia") +
  ylim(c(0,60)) +
  xlim(c(36,50)) +
  ggtitle("Distribución de promedios de edades de docentes de 400 muestras") +
  theme_bw(base_size = 11) +
  geom_text(geom = "text",label="colour=red,\n fill=skyblue", x=25,y=50,col="black") +
  theme(
    text = element_text(size = 13),
    axis.text.x = element_text(color = "black",angle = 0, hjust = 0.5),
    # text = element_text(size = 15),
    axis.text.y = element_text(color = "black",angle = 0, hjust = 0.5),
    legend.position = "none"
  ) +
  annotate("text", x = gran_avg$promedio+2, y=55, label = paste0("Gran promedio = ", round(gran_avg$promedio, 2)))
```

Distribución de promedios de edades de docentes



7 Pregunta d

 Ver solución

Por definición, la desviación estándar se determina utilizando la siguiente expresión:

$$\sigma_{\bar{x}} = \sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$$

En este caso, como buscamos la desviación estándar de las medias muestrales, entonces x_i corresponde al promedio de cada muestra ($\bar{x}_{m_1}, \bar{x}_{m_2}, \bar{x}_{m_3}, \dots, \bar{x}_{m_{400}}$), n el número total de muestras (400 en este caso) y $\bar{x}$ el promedio de la distribución muestral (el gran promedio). Si se aplica esta expresión, la desviación estándar de la distribución de los promedios muestrales es $\sigma_{\bar{x}} = 2.11$ años.

8 Pregunta e

 Ver solución

Si utilizamos la distribución de la media muestral construida en esta actividad, notaremos que son 264 las muestras que se encuentran dentro de un rango $\pm 1\sigma_{\bar{x}}$ (note que una desviación estándar a la derecha del promedio toma el valor de edad $42.66 + 2.11 = 44.77$ y una desviación estándar a la izquierda del promedio toma el valor $42.66 - 2.11 = 40.55$, y si contamos la cantidad de muestras cuyos promedios están comprendidos entre este rango, notará que son 264. Con respecto al total, esta cantidad equivale a un 66 % aproximadamente.

De manera análoga similar, notaremos ahora que son 386 las muestras que se encuentran dentro de un rango $\pm 2\sigma_{\bar{x}}$ (note que dos desviaciones estándar a la derecha del promedio toma el valor de edad $42.66 + 2 * 2.11 = 46.88$ y una desviación estándar a la izquierda del promedio toma el valor $42.66 - 2 * 2.11 = 38.44$, y si contamos la cantidad de muestras cuyos promedios están comprendidos entre este rango, notará que son 386. Con respecto al total, esta cantidad equivale a un 96.5 % aproximadamente.

9 Actividad Aplicada 1: Teorema Límite Central

A partir de las respuestas previas correspondientes a las 400 muestras, ahora interesa describir la distribución de la media muestral $\bar{x}$, entendida como el conjunto de los promedios

de edad calculados para cada muestra.². Para ello:

- Indique la media de la distribución de los promedios muestrales $\bar{x}$.
- Indique la desviación estándar de la distribución de los promedios muestrales $\sigma_{\bar{x}}$.
- Aplicando el Teorema del límite central, indique qué tipo de distribución captura la distribución de la media muestral e indique sus parámetros.
- ¿Cuál es la proporción aproximada de muestras que se concentran a $\pm 1\sigma_{\bar{x}}$ en torno a la media de la distribución de los promedios muestrales ($\bar{x}$)?
- Construya ahora un intervalo en torno a la media de la distribución de los promedios muestrales. En términos simples, esto significa tomar la media muestral ($\bar{x}$) y luego sumar y restar una desviación estándar ($\sigma_{\bar{x}}$) de esta distribución. Al sumar una desviación estándar obtendrá el límite superior del intervalo, y al restarla obtendrá el límite inferior del intervalo. Este procedimiento permite determinar el margen de error en torno a la media muestral, generando así el intervalo deseado. Este intervalo se expresa en términos matemáticos de la siguiente forma:

$$\bar{x} \pm 1 \cdot \sigma_{\bar{x}}$$

- ¿Cuál es aproximadamente la probabilidad cubierta (confianza) para la estimación de este intervalo? Esta es una pregunta crucial para comprender los fundamentos que están detrás en la construcción de un intervalo (de confianza).

Solución

10 Pregunta a

Ver solución

Utilizando la respuesta a la pregunta 2.2c de la sección anterior, se tiene que la media de la distribución de los promedios muestrales es $\bar{x} = 42.66$ años.

²Si es la primera vez que lee esta explicación podría parecer algo confusa. Veámoslo más sencillo: tenemos 40 muestras, cada una compuesta por 30 docentes. Para cada una de estas muestras calculamos la edad promedio. Al hacer esto, obtenemos 40 promedios diferentes. Si representamos estos 40 promedios en un histograma, obtendremos la distribución de los promedios muestrales. Lo que estamos pidiendo aquí es describir cómo es esta distribución de promedios o, más precisamente, la media general de estos 40 promedios.

11 Pregunta b

 Ver solución

Utilizando la respuesta a la pregunta 2.2d de la sección anterior, se tiene que la desviación estándar de la distribución de los promedios muestrales $\sigma_{\bar{x}} = 2.11$ años.

12 Pregunta c

 Ver solución

Aplicando el Teorema del Límite Central (TLC), se puede afirmar que la distribución de la media muestral $\bar{x}$ puede aproximarse mediante una distribución normal con media 42.66 y desviación estándar 2.11. Dado que una distribución normal queda completamente determinada por estos dos parámetros, esta aproximación se expresa matemáticamente como:

$$\bar{x} \sim \mathcal{N}(42.66, 2.11)$$

13 Pregunta d

 Ver solución

Si utilizamos la distribución de la media muestral construida en la sección anterior, notaremos que son 264 las muestras que se encuentran dentro de un rango $\pm 1\sigma_{\bar{x}}$. En este caso, note que una desviación estándar a la derecha del promedio toma el valor de edad $42.66 + 2.11 = 44.77$ y una desviación estándar a la izquierda del promedio toma el valor $42.66 - 2.11 = 40.55$, y si contamos la cantidad de muestras cuyos promedios están comprendidos entre este rango, notará que son 264. Con respecto al total, esta cantidad equivale a un 66 % aproximadamente.

Ahora bien, si en lugar de haber recolectado 400 muestras, se hubiese considerado una cantidad infinita de muestras, es decir, el caso límite en el que es posible obtener infinitas muestras, la proporción de casos dentro de una desviación estándar respecto de la media ($\pm 1\sigma_{\bar{x}}$) habría sido exactamente del 68%. Esta proporción corresponde a la propiedad de simetría de la distribución normal, resultado que se deriva aplicando el Teorema del Límite Central (TLC).

14 Pregunta e

💡 Ver solución

Para construir el intervalo, es necesario estimar sus límites inferior y superior. El límite inferior se obtiene restando una desviación estándar a la media muestral, es decir, $\bar{x} - 1 \cdot \sigma_{\bar{x}}$. Por su parte, el límite superior se estima sumando una desviación estándar a la media: $\bar{x} + 1 \cdot \sigma_{\bar{x}}$. Luego,

$$\begin{aligned}\text{Límite inferior} &= \bar{x} - 1 \cdot \sigma_{\bar{x}} \\ &= 42.66 - 1 \cdot 2.11 \\ &= 40.55\end{aligned}$$

y

$$\begin{aligned}\text{Límite superior} &= \bar{x} + 1 \cdot \sigma_{\bar{x}} \\ &= 42.66 + 1 \cdot 2.11 \\ &= 44.77\end{aligned}$$

Luego, el intervalo solicitado quedaría de la siguiente forma:

$$[\text{Límite inferior}, \text{Límite superior}] = [40.55, 44.77]$$

Por lo tanto, para la distribución de la media muestral usada en este ejercicio con fines pedagógicos, la probabilidad cubierta para la estimación de este intervalo sería de un 66%, porcentaje que obtuvimos anteriormente en la Pregunta 2.2 e).

15 Actividad Aplicada 2: Intervalo de confianza

Utilizando lo realizado en las preguntas anteriores, responda:

- a. ¿Dentro de qué límites se esperaría que esté el promedio poblacional, con probabilidad (cobertura) de .95? Considerando que si se trabaja con una distribución normal, un intervalo para la media con probabilidad de cobertura de .95, considera que el 95% de los valores están contenidos dentro de ± 1.96 desviaciones estándar con respecto a la media. Esto típicamente se conoce como la *Regla empírica*. Entonces se buscan los valores dados por

$$L_{\text{límites}} = \bar{x} \pm Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

donde $\bar{x}$ es la media muestral, $Z_{\alpha/2}$ es el valor 1.96, σ la desviación estándar poblacional y n el tamaño de la muestra.

- b. Construya ahora un intervalo de confianza al 95% utilizando el promedio de la muestra que le fue asignada. ¿El promedio de edad de la población ($\mu = 42.77$) se encuentra dentro de este intervalo?

Solución

16 Pregunta a

 Ver solución

Para estimar los límites del intervalo, utilizamos un intervalo de confianza del 95%, asumiendo que la distribución de la media muestral puede ser aproximada por una distribución normal. Esta aproximación se justifica mediante el Teorema del Límite Central (TLC). Luego, para la estimación de los límites del intervalo utilizaremos la siguiente expresión:

$$L_{\text{límites}} = \bar{x} \pm Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

donde,

$$\bar{x} = 42.66, \quad Z_{\alpha/2} = 1.96, \quad \sigma = 11.91, \quad n = 30$$

Con esto, se tiene que $\frac{\sigma}{\sqrt{n}} \approx 2.17$. Reemplazando los valores en la expresión anterior, se obtiene:

$$\begin{aligned} L_{\text{límites}} &= 42.66 \pm (1.96 \cdot 2.17) \\ &= 42.66 \pm 4.25 \end{aligned}$$

Por lo tanto, los límites del intervalo quedan:

$$L_{\text{límites}} = [38.41, 46.91]$$

Por lo tanto, con una probabilidad de cobertura del 95%, se espera que el promedio poblacional se encuentre entre 38.41 y 46.91 años.

17 Pregunta b

💡 Ver solución

```
Rows: 400
Columns: 7
Groups: grupo [10]
$ grupo      <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ muestra     <chr> "m_1", "m_101", "m_11", "m_111", "m_121", "m_131", "m_1~
$ stat_mean   <dbl> 42.83333, 45.76667, 43.80000, 41.93333, 44.43333, 43.70~
$ standard_error <dbl> 2.174459, 2.174459, 2.174459, 2.174459, 2.174459, 2.174~
$ ll          <dbl> 38.57139, 41.50473, 39.53806, 37.67139, 40.17139, 39.43~
$ ul          <dbl> 47.09527, 50.02861, 48.06194, 46.19527, 48.69527, 47.96~
$ status      <chr> "yes", "yes", "yes", "yes", "yes", "yes", "yes", "yes", "yes", ~
```

Aquellas muestras cuyos intervalos de confianza estimados al 95% que no contienen al parámetro poblacional ($\mu = 42.77$) son las siguientes: m_251, m_192, m_282, m_155, m_175, m_235, m_305, m_335, m_316, m_207, m_237, m_278, m_239, m_309, m_290, m_340. Con respecto al total de muestras, esta cantidad equivale al $\frac{16}{400} * 100 = 4\%$, en otras palabras, el 4% de todos los intervalos de confianza estimados no contiene al promedio poblacional. Para más detalles de los intervalos estimados para estas muestras, puede consultar la siguiente tabla.

1	m_251	42.77	[34.238 , 42.762]	No contiene al parametro poblacional
2	m_192	42.77	[33.938 , 42.462]	No contiene al parametro poblacional
2	m_282	42.77	[42.871 , 51.395]	No contiene al parametro poblacional
5	m_155	42.77	[33.671 , 42.195]	No contiene al parametro poblacional
5	m_175	42.77	[44.238 , 52.762]	No contiene al parametro poblacional
5	m_235	42.77	[33.271 , 41.795]	No contiene al parametro poblacional
5	m_305	42.77	[44.171 , 52.695]	No contiene al parametro poblacional
5	m_335	42.77	[43.271 , 51.795]	No contiene al parametro poblacional
6	m_316	42.77	[43.438 , 51.962]	No contiene al parametro poblacional
7	m_207	42.77	[33.571 , 42.095]	No contiene al parametro poblacional
7	m_237	42.77	[43.305 , 51.829]	No contiene al parametro poblacional
8	m_278	42.77	[34.171 , 42.695]	No contiene al parametro poblacional
9	m_239	42.77	[45.471 , 53.995]	No contiene al parametro poblacional
9	m_309	42.77	[44.438 , 52.962]	No contiene al parametro poblacional
10	m_290	42.77	[34.205 , 42.729]	No contiene al parametro poblacional
10	m_340	42.77	[34.071 , 42.595]	No contiene al parametro poblacional

18 Actividad Aplicada 3 (avanzado): Probabilidad de cobertura

Utilizando la distribución de los promedios muestrales, responda:

- a. Calcule la probabilidad de que la media muestral $\bar{x}$ de los promedios de las edades sea mayor a 48 años. Utilice R para determinarla.
- b. Si su muestra aleatoria tiene una media muestral de 48 años, ¿consideraría usted que esto es poco común? ¿Qué conclusión podría sacar?

Solución

19 Pregunta a

Ver solución

La probabilidad se calcula como el área bajo la curva normal *estándar* para valores mayores que 48. Primero, transformamos 48 a una puntuación Z :

$$Z = \frac{\bar{x} - \mu_{\bar{x}}}{\sigma_{\bar{x}}}$$

Sustituimos los valores:

$$Z = \frac{48 - 42.66}{2.11} \approx 2.53$$

Ahora, consultamos la tabla de la distribución normal estándar o utilizamos R. Típicamente, para determinar probabilidades acumuladas se usa el comando `pnorm()`. La probabilidad acumulada para $Z = 2.53$ es aproximadamente:

$$P(Z \leq 2.53) \approx 0.994$$

La probabilidad de que $\bar{x}$ sea mayor a 48 es el complemento, dado que el área bajo la curva normal es 1. Entonces tenemos:

$$P(Z > 2.53) = 1 - P(Z \leq 2.53) \approx 1 - 0.994 \approx 0.005$$

Por lo tanto, la probabilidad de que la media muestral sea mayor a 48 años es aproximadamente 0.005 o 0.5%.

En R tenemos:

```

x_barra <- 48 # Valor de la media muestral
mu_x_barra <- 42.66 # Valor del promedio de la distribución de la media muestral
sigma_x_barra <- 2.11 # Valor de la desviación estándar de la distribución de la media muestral

# Calcular la puntuación Z
Z <- (x_barra - mu_x_barra) / sigma_x_barra

# Calcular la probabilidad acumulada para Z con el comando pnorm()
probabilidad_acumulada <- pnorm(Z)

# Calcular la probabilidad de que X barra sea mayor a 48
probabilidad_mayor <- 1 - probabilidad_acumulada

# Mostrar el resultado
probabilidad_mayor

```

20 Pregunta b

 Ver solución

¿Es poco común que la media muestral sea de 48 años? Un evento se considera “poco común” si su probabilidad es muy baja, típicamente menos del 5% ($P < 0.05$). En este caso, la probabilidad de obtener una media muestral mayor a 48 es 0.5%, lo que es sumamente bajo.

Hay evidencia suficiente para considerar que esta media muestral es poco común. Si esta media muestral fuera observada, podríamos cuestionar si es consistente con el promedio poblacional o si hay factores adicionales que están afectando los resultados.