

Actividad Formativa 01

Teorema del Límite Central

Dany Lopez (dxlopez@ul.cl) - José Luis Pérez (josel.perez@uc.cl)

Contenido


1 Contexto	2
2 Actividad Introductoria	3
2.1 Análisis de un grupo con 40 muestras	3
3 Pregunta d.1)	3
3.1 Análisis considerando las 400 muestras	4
4 Pregunta a	4
5 Pregunta b	13
6 Pregunta c	14
7 Pregunta d	16
8 Pregunta e	16
9 Actividad Aplicada 1: Teorema Límite Central	16
10 Pregunta a	17
11 Pregunta b	18
12 Pregunta c	18
13 Pregunta d	18
14 Pregunta e	19
15 Actividad Aplicada 2: Intervalo de confianza	19

16 Pregunta a	20
17 Pregunta b	21
18 Actividad Aplicada 3 (avanzado): Probabilidad de cobertura	22
19 Pregunta a	23
20 Pregunta b	25

1 Contexto

Suponga que se desarrolla un estudio que busca caracterizar sociodemográficamente a las y los docentes de todas las escuelas del país, incluyendo escuelas públicas, subvencionadas, privadas, y del Servicio Local de Educación Pública (SLEP). En particular, se tiene como objetivo determinar la edad promedio de los docentes que se desempeñan durante el año 2024 en las escuelas del país.

Usaremos los datos de **Cargo Docente** del año 2024 proporcionada por el **Centro de Estudios Mineduc**. Estos datos corresponden a la información censal de todos los docentes del sistema escolar que tienen un cargo en al menos una escuela durante el año 2024.



La cantidad total de docentes con cargo en el sistema escolar equivale a 266,069. La edad promedio de la población de docentes es de $\mu = 42.77$ años, con una desviación estándar de $\sigma = 11.91$ años. En un intento por verificar el rango etario promedio, se seleccionaron 400 muestras aleatorias de tamaño $N = 30$ docentes cada muestra. A partir de estas 400 muestras se construyeron 10 grupos, con cada grupo compuesto por 40 muestras. Puede acceder al listado de muestras para cada grupo en el siguiente link: [ver aquí](#)

Note que los datos que usaremos son los mismos que utilizamos en la primera actividad [ver detalle actividad aquí](#).

2 Actividad Introductoria

2.1 Análisis de un grupo con 40 muestras

- Identifique el número de grupo que le fue asignado en la clase 01. Si no estuvo presente en la primera clase, seleccione un grupo con el que desea trabajar. De manera similar a como lo trabajó en la primera clase, calcule el promedio de cada muestra. Puede utilizar Excel, BlueSky Statistics o R para calcular el promedio.
- Calcule ahora el promedio de todos los promedios muestrales. Puede utilizar Excel, BlueSky Statistics o R para calcular el promedio.
- Con los promedios de cada muestra ahora construya un gráfico de frecuencias. En el mismo gráfico, represente el promedio de todos los promedios (puede hacerlo dentro del gráfico marcando con un punto o una línea la ubicación del promedio).
- Una vez que haya graficado, observe el resultado que se obtiene y luego responda las siguientes preguntas:
 - ¿Qué representa el gráfico?
 - ¿Entre qué rangos se concentran la mayoría de los promedios de las edades de las muestras?

Nota: Las respuestas de esta sección fueron contestadas en clases. Recomendamos mirar la grabación de la segunda clase del curso que se encuentra en TEAMS para contestarlas.

Solución

3 Pregunta d.1)

Ver solución d.1

El gráfico corresponde a un histograma de frecuencias, utilizado para representar la distribución de un conjunto de datos cuantitativos. A diferencia del gráfico de barras, empleado para variables cualitativas, el histograma utiliza barras contiguas cuya altura indica la frecuencia relativa (o proporción) de observaciones que se encuentran dentro de determinados subintervalos del dominio. Estos subintervalos se disponen de manera ordenada a lo largo del eje horizontal. Para mayores detalles, consulte las siguientes referencias¹:

[1] Field, A. P., Miles, J., & Field, Z. (2012). *Discovering statistics using R*. London; Thousand Oaks, Calif.: Sage. p. 142-144

[2] Mendenhall, W., & Beaver, B. M. (2011). *Introducción a la probabilidad y estadística*

3.1 Análisis considerando las 400 muestras

Ahora incluiremos todas las muestras de todos los grupos, es decir, consideraemos la colección total de 400 muestras de tamaño $N = 30$ cada una. Responda las siguientes preguntas:

- Calcule el promedio de cada una de las muestras.
- Construya un histograma de frecuencias con los 400 promedios muestrales.
- Calcule el promedio de todos los promedios (el gran promedio) y ubíquelo en el gráfico de frecuencia.
- Ahora calcule la desviación estándar de los promedios muestrales $\sigma_{\bar{x}}$.
- Ahora, cuente cuántos promedios muestrales se ubican a $\pm 1\sigma_{\bar{x}}$ en torno al gran promedio. Y ¿Cuántos promedios muestrales se ubican a $\pm 2\sigma_{\bar{x}}$ en torno al gran promedio?

Solución

4 Pregunta a

Ver solución

Por definición, la media se estima por medio de la siguiente expresión:

$$\bar{x} = \frac{\sum_1^n x_i}{n} = \frac{x_1 + x_2 + x_3 + x_4 + \cdots + x_{n-1} + x_n}{n}$$

con x_i la edad del docente i y n el número total de individuos. La expresión anterior significa que debemos sumar todas las edades en una muestra y dividir este resultado por el número total de docentes que forma parte de dicha muestra. Para ilustrar su aplicación, consideremos la muestra m_1 . Dado que la muestra m_1 está compuesta $n = 30$ docentes (lo mismo para todas las demás muestras), entonces la expresión para calcular el promedio queda

¹ Estas referencias se encuentran en Canvas, en la clase 02.

$$\begin{aligned}
\bar{x}_{m_1} &= \frac{\sum_1^{30} x_i}{30} \\
&= \frac{x_1 + x_2 + x_3 + x_4 + x_5 + \dots + x_{26} + x_{27} + x_{28} + x_{29} + x_{30}}{30} \\
&= \frac{31 + 31 + 57 + 41 + 49 + \dots + 31 + 42 + 43 + 27 + 54}{30} \\
&= 42.8
\end{aligned}$$

Así, la muestra m_1 tiene un promedio $\bar{x}_{m_1} = 42.8$. Usando entonces la misma expresión para el resto de las muestra, en la siguiente tabla se muestran todos los promedios calculados para cada muestra:

muestra	promedio
m_1	42.83333
m_10	42.53333
m_100	42.73333
m_101	45.76667
m_102	45.33333
m_103	43.50000
m_104	40.50000
m_105	41.40000
m_106	42.36667
m_107	41.53333
m_108	44.16667
m_109	42.96667
m_11	43.80000
m_110	40.56667
m_111	41.93333
m_112	44.83333
m_113	45.16667
m_114	40.86667
m_115	39.10000
m_116	45.10000
m_117	43.00000
m_118	42.80000
m_119	40.30000
m_12	42.80000
m_120	40.90000
m_121	44.43333
m_122	42.86667
m_123	43.36667
m_124	43.96667
m_125	42.00000
m_126	43.96667
m_127	39.96667
m_128	42.13333
m_129	41.76667
m_13	39.66667

m_130	43.86667
m_131	43.70000
m_132	43.40000
m_133	41.33333
m_134	44.36667
m_135	44.03333
m_136	42.86667
m_137	43.70000
m_138	42.66667
m_139	41.53333
m_14	44.16667
m_140	45.03333
m_141	41.66667
m_142	42.96667
m_143	44.76667
m_144	41.60000
m_145	42.60000
m_146	40.50000
m_147	43.23333
m_148	43.23333
m_149	42.76667
m_15	40.13333
m_150	43.53333
m_151	44.26667
m_152	43.93333
m_153	45.43333
m_154	41.40000
m_155	37.93333
m_156	42.36667
m_157	44.30000
m_158	42.10000
m_159	42.86667
m_16	44.83333
m_160	40.60000
m_161	38.73333
m_162	45.16667
m_163	42.73333
m_164	42.30000
m_165	42.23333
m_166	42.30000
m_167	41.80000
m_168	43.66667
m_169	38.80000
m_17	43.80000
m_170	41.36667
m_171	45.83333
m_172	40.63333
m_173	42.86667
m_174	44.20000
m_175	48.50000

m_176	40.30000
m_177	42.26667
m_178	45.96667
m_179	46.76667
m_18	39.70000
m_180	43.33333
m_181	41.33333
m_182	44.60000
m_183	38.66667
m_184	41.26667
m_185	45.90000
m_186	41.90000
m_187	39.16667
m_188	41.36667
m_189	40.36667
m_19	43.50000
m_190	45.73333
m_191	44.66667
m_192	38.20000
m_193	46.50000
m_194	45.43333
m_195	41.70000
m_196	44.46667
m_197	42.56667
m_198	44.40000
m_199	42.96667
m_2	44.50000
m_20	42.56667
m_200	42.33333
m_201	42.26667
m_202	44.63333
m_203	42.70000
m_204	45.03333
m_205	40.70000
m_206	39.60000
m_207	37.83333
m_208	41.50000
m_209	46.23333
m_21	42.30000
m_210	43.76667
m_211	42.46667
m_212	43.83333
m_213	41.83333
m_214	39.66667
m_215	44.30000
m_216	43.50000
m_217	45.26667
m_218	41.60000
m_219	45.36667
m_22	44.80000

m_220	44.96667
m_221	42.23333
m_222	41.96667
m_223	44.06667
m_224	43.63333
m_225	40.13333
m_226	40.53333
m_227	42.20000
m_228	44.83333
m_229	43.00000
m_23	39.93333
m_230	43.83333
m_231	40.10000
m_232	41.00000
m_233	42.60000
m_234	39.40000
m_235	37.53333
m_236	43.56667
m_237	47.56667
m_238	41.43333
m_239	49.73333
m_24	45.70000
m_240	42.36667
m_241	41.03333
m_242	40.13333
m_243	44.36667
m_244	42.36667
m_245	40.36667
m_246	42.23333
m_247	42.13333
m_248	39.66667
m_249	43.40000
m_25	44.96667
m_250	46.73333
m_251	38.50000
m_252	46.40000
m_253	39.73333
m_254	46.33333
m_255	41.53333
m_256	39.40000
m_257	45.36667
m_258	43.13333
m_259	42.66667
m_26	40.90000
m_260	43.70000
m_261	40.56667
m_262	43.76667
m_263	42.50000
m_264	43.16667
m_265	44.96667

m_266	41.46667
m_267	38.86667
m_268	44.13333
m_269	41.80000
m_27	40.73333
m_270	45.83333
m_271	43.76667
m_272	44.46667
m_273	43.90000
m_274	42.53333
m_275	45.16667
m_276	40.43333
m_277	40.13333
m_278	38.43333
m_279	41.13333
m_28	39.73333
m_280	44.90000
m_281	43.66667
m_282	47.13333
m_283	42.40000
m_284	46.83333
m_285	42.66667
m_286	45.76667
m_287	44.00000
m_288	43.96667
m_289	42.53333
m_29	43.90000
m_290	38.46667
m_291	41.16667
m_292	42.70000
m_293	41.76667
m_294	41.06667
m_295	39.50000
m_296	44.90000
m_297	41.60000
m_298	42.03333
m_299	41.00000
m_3	39.70000
m_30	43.10000
m_300	45.03333
m_301	42.23333
m_302	41.66667
m_303	42.63333
m_304	42.40000
m_305	48.43333
m_306	45.40000
m_307	39.93333
m_308	40.20000
m_309	48.70000
m_31	42.13333

m_310	45.26667
m_311	45.73333
m_312	44.13333
m_313	40.63333
m_314	45.26667
m_315	44.00000
m_316	47.70000
m_317	42.30000
m_318	42.50000
m_319	46.70000
m_32	45.50000
m_320	43.06667
m_321	43.13333
m_322	41.06667
m_323	42.63333
m_324	42.13333
m_325	45.03333
m_326	40.70000
m_327	40.33333
m_328	39.50000
m_329	42.40000
m_33	40.13333
m_330	42.26667
m_331	38.73333
m_332	41.83333
m_333	42.00000
m_334	43.63333
m_335	47.53333
m_336	39.00000
m_337	43.03333
m_338	39.30000
m_339	43.03333
m_34	45.83333
m_340	38.33333
m_341	40.36667
m_342	43.20000
m_343	40.50000
m_344	43.50000
m_345	38.63333
m_346	41.30000
m_347	43.36667
m_348	39.70000
m_349	44.40000
m_35	43.73333
m_350	42.53333
m_351	40.86667
m_352	39.60000
m_353	43.50000
m_354	43.53333
m_355	41.26667

m_356	41.56667
m_357	43.30000
m_358	43.90000
m_359	40.23333
m_36	43.50000
m_360	44.26667
m_361	44.93333
m_362	43.26667
m_363	42.06667
m_364	42.50000
m_365	45.80000
m_366	41.16667
m_367	39.73333
m_368	41.26667
m_369	43.40000
m_37	43.63333
m_370	40.53333
m_371	43.03333
m_372	40.93333
m_373	43.66667
m_374	42.96667
m_375	39.86667
m_376	41.46667
m_377	43.43333
m_378	41.76667
m_379	44.50000
m_38	41.63333
m_380	41.20000
m_381	44.36667
m_382	39.16667
m_383	42.86667
m_384	40.86667
m_385	44.10000
m_386	45.53333
m_387	42.56667
m_388	44.33333
m_389	43.70000
m_39	44.13333
m_390	42.20000
m_391	45.23333
m_392	45.70000
m_393	43.56667
m_394	41.73333
m_395	42.40000
m_396	42.56667
m_397	43.53333
m_398	38.60000
m_399	40.86667
m_4	42.26667
m_40	44.53333

m_400	41.83333
m_41	42.56667
m_42	39.83333
m_43	39.40000
m_44	41.36667
m_45	40.50000
m_46	42.30000
m_47	40.60000
m_48	43.70000
m_49	41.70000
m_5	45.13333
m_50	46.46667
m_51	41.96667
m_52	40.00000
m_53	39.26667
m_54	39.70000
m_55	42.06667
m_56	45.33333
m_57	42.83333
m_58	45.33333
m_59	42.46667
m_6	41.53333
m_60	41.43333
m_61	43.03333
m_62	41.70000
m_63	46.36667
m_64	40.56667
m_65	44.80000
m_66	44.16667
m_67	42.83333
m_68	43.73333
m_69	44.63333
m_7	38.93333
m_70	43.40000
m_71	41.50000
m_72	41.03333
m_73	46.06667
m_74	43.36667
m_75	41.83333
m_76	44.20000
m_77	40.90000
m_78	41.53333
m_79	45.16667
m_8	44.90000
m_80	43.66667
m_81	41.73333
m_82	41.56667
m_83	44.63333
m_84	42.00000
m_85	44.86667

m_86	42.86667
m_87	43.70000
m_88	41.63333
m_89	44.43333
m_9	40.56667
m_90	44.50000
m_91	42.50000
m_92	38.83333
m_93	42.16667
m_94	42.43333
m_95	42.80000
m_96	39.93333
m_97	41.96667
m_98	42.63333
m_99	41.20000


5 Pregunta b

💡 Ver solución

El histograma de frecuencias de los promedios de la 400 muestras se muestra a continuación.

```
library(ggplot2)

ggplot(promedio_muestras, aes(x = as.numeric(promedio))) +
  geom_histogram(binwidth=0.6, colour="#56B4E9", fill="skyblue") +
  labs(x="Edad", y= "Frecuencia") +
  ylim(c(0,60)) +
  xlim(c(36,50)) +
  ggtitle("Distribución de promedios muestrales de edades de 400 muestras") +
  theme_bw(base_size = 11) +
  geom_text(geom = "text", label="colour=red,\n fill=skyblue", x=25,y=50,col="black") +
  theme(
    text = element_text(size = 13),
    axis.text.x = element_text(color = "black",angle = 0, hjust = 0.5),
    # text = element_text(size = 15),
    axis.text.y = element_text(color = "black",angle = 0, hjust = 0.5),
    legend.position = "none"
  )
```



6 Pregunta c

💡 Ver solución

El promedio de todos los promedios equivale a 42.66 años. A continuación se muestra su ubicación en el histograma construido anteriormente

```


library(ggplot2)

gran_avg <- db %>%
  dplyr::summarise(promedio = mean(edad, na.rm = T))

ggplot(promedio_muestras, aes(x = as.numeric(promedio))) +
  geom_histogram(binwidth=0.6, colour="#56B4E9", fill="skyblue") +
  geom_vline(xintercept = gran_avg$promedio ) +

  labs(x="Edad",y= "Frecuencia") +
  ylim(c(0,60)) +
  xlim(c(36,50)) +
  ggtitle("Distribución de promedios de edades de docentes de 400 muestras") +
  theme_bw(base_size = 11) +
  geom_text(geom = "text",label="colour=red,\n fill=skyblue", x=25,y=50,col="black") +
  theme(
    text = element_text(size = 13),
    axis.text.x = element_text(color = "black",angle = 0, hjust = 0.5),
    # text = element_text(size = 15),
    axis.text.y = element_text(color = "black",angle = 0, hjust = 0.5),
    legend.position = "none"
  ) +
  annotate("text", x = gran_avg$promedio+2, y=55, label = paste0("Gran promedio = ", round(gran_avg$

```



7 Pregunta d

 Ver solución

Por definición, la desviación estándar se determina utilizando la siguiente expresión:

$$\sigma_{\bar{x}} = \sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$$

En este caso, como buscamos la desviación estándar de las medias muestrales, entonces x_i corresponde al promedio de cada muestra ($\bar{x}_{m_1}, \bar{x}_{m_2}, \bar{x}_{m_3}, \dots, \bar{x}_{m_{400}}$), n el número total de muestras (400 en este caso) y $\bar{x}$ el promedio de la distribución muestral (el gran promedio). Si se aplica esta expresión, la desviación estándar de la distribución de los promedios muestrales es $\sigma_{\bar{x}} = 2.11$ años.

8 Pregunta e

 Ver solución

Si utilizamos la distribución de la media muestral construida en esta actividad, notaremos que son 264 las muestras que se encuentran dentro de un rango $\pm 1\sigma_{\bar{x}}$ (note que una desviación estándar a la derecha del promedio toma el valor de edad $42.66 + 2.11 = 44.77$ y una desviación estándar a la izquierda del promedio toma el valor $42.66 - 2.11 = 40.55$, y si contamos la cantidad de muestras cuyos promedios están comprendidos entre este rango, notará que son 264. Con respecto al total, esta cantidad equivale a un 66 % aproximadamente.

De manera análoga similar, notaremos ahora que son 386 las muestras que se encuentran dentro de un rango $\pm 2\sigma_{\bar{x}}$ (note que dos desviaciones estándar a la derecha del promedio toma el valor de edad $42.66 + 2 * 2.11 = 46.88$ y una desviación estándar a la izquierda del promedio toma el valor $42.66 - 2 * 2.11 = 38.44$, y si contamos la cantidad de muestras cuyos promedios están comprendidos entre este rango, notará que son 386. Con respecto al total, esta cantidad equivale a un 96.5 % aproximadamente.

9 Actividad Aplicada 1: Teorema Límite Central

A partir de las respuestas previas correspondientes a las 400 muestras, ahora interesa describir la distribución de la media muestral $\bar{x}$, entendida como el conjunto de los promedios

de edad calculados para cada muestra.². Para ello:

- Indique la media de la distribución de los promedios muestrales $\bar{x}$.
- Indique la desviación estándar de la distribución de los promedios muestrales $\sigma_{\bar{x}}$.
- Aplicando el Teorema del límite central, indique qué tipo de distribución captura la distribución de la media muestral e indique sus parámetros.
- ¿Cuál es la proporción aproximada de muestras que se concentran a $\pm 1\sigma_{\bar{x}}$ en torno a la media de la distribución de los promedios muestrales ($\bar{x}$)?
- Construya ahora un intervalo en torno a la media de la distribución de los promedios muestrales. En términos simples, esto significa tomar la media muestral ($\bar{x}$) y luego sumar y restar una desviación estándar ($\sigma_{\bar{x}}$) de esta distribución. Al sumar una desviación estándar obtendrá el límite superior del intervalo, y al restarla obtendrá el límite inferior del intervalo. Este procedimiento permite determinar el margen de error en torno a la media muestral, generando así el intervalo deseado. Este intervalo se expresa en términos matemáticos de la siguiente forma:

$$\bar{x} \pm 1 \cdot \sigma_{\bar{x}}$$

- ¿Cuál es aproximadamente la probabilidad cubierta (confianza) para la estimación de este intervalo? Esta es una pregunta crucial para comprender los fundamentos que están detrás en la construcción de un intervalo (de confianza).

Solución

10 Pregunta a

Ver solución

Utilizando la respuesta a la pregunta 2.2c de la sección anterior, se tiene que la media de la distribución de los promedios muestrales es $\bar{x} = 42.66$ años.

²Si es la primera vez que lee esta explicación podría parecer algo confusa. Veámoslo más sencillo: tenemos 40 muestras, cada una compuesta por 30 docentes. Para cada una de estas muestras calculamos la edad promedio. Al hacer esto, obtenemos 40 promedios diferentes. Si representamos estos 40 promedios en un histograma, obtendremos la distribución de los promedios muestrales. Lo que estamos pidiendo aquí es describir cómo es esta distribución de promedios o, más precisamente, la media general de estos 40 promedios.

11 Pregunta b

 Ver solución

Utilizando la respuesta a la pregunta 2.2d de la sección anterior, se tiene que la desviación estándar de la distribución de los promedios muestrales $\sigma_{\bar{x}} = 2.11$ años.

12 Pregunta c

 Ver solución

Aplicando el Teorema del Límite Central (TLC), se puede afirmar que la distribución de la media muestral $\bar{x}$ puede aproximarse mediante una distribución normal con media 42.66 y desviación estándar 2.11. Dado que una distribución normal queda completamente determinada por estos dos parámetros, esta aproximación se expresa matemáticamente como:

$$\bar{x} \sim \mathcal{N}(42.66, 2.11)$$

13 Pregunta d

 Ver solución

Si utilizamos la distribución de la media muestral construída en la sección anterior, notaremos que son 264 las muestras que se encuentran dentro de un rango $\pm 1\sigma_{\bar{x}}$. En este caso, note que una desviación estándar a la derecha del promedio toma el valor de edad $42.66 + 2.11 = 44.77$ y una desviación estándar a la izquierda del promedio toma el valor $42.66 - 2.11 = 40.55$, y si contamos la cantidad de muestras cuyos promedios están comprendidos entre este rango, notará que son 264. Con respecto al total, esta cantidad equivale a un 66 % aproximadamente.

Ahora bien, si en lugar de haber recolectado 400 muestras, se hubiese considerado una cantidad infinita de muestras, es decir, el caso límite en el que es posible obtener infinitas muestras, la proporción de casos dentro de una desviación estándar respecto de la media ($\pm 1\sigma_{\bar{x}}$) habría sido exactamente del 68%. Esta proporción corresponde a la propiedad de simetría de la distribución normal, resultado que se deriva aplicando el Teorema del Límite Central (TLC).

14 Pregunta e

💡 Ver solución

Para construir el intervalo, es necesario estimar sus límites inferior y superior. El límite inferior se obtiene restando una desviación estándar a la media muestral, es decir, $\bar{x} - 1 \cdot \sigma_{\bar{x}}$. Por su parte, el límite superior se estima sumando una desviación estándar a la media: $\bar{x} + 1 \cdot \sigma_{\bar{x}}$. Luego,

$$\begin{aligned}\text{Límite inferior} &= \bar{x} - 1 \cdot \sigma_{\bar{x}} \\ &= 42.66 - 1 \cdot 2.11 \\ &= 40.55\end{aligned}$$

y

$$\begin{aligned}\text{Límite superior} &= \bar{x} + 1 \cdot \sigma_{\bar{x}} \\ &= 42.66 + 1 \cdot 2.11 \\ &= 44.77\end{aligned}$$

Luego, el intervalo solicitado quedaría de la siguiente forma:

$$[\text{Límite inferior}, \text{Límite superior}] = [40.55, 44.77]$$

Por lo tanto, para la distribución de la media muestral usada en este ejercicio con fines pedagógicos, la probabilidad cubierta para la estimación de este intervalo sería de un 66%, porcentaje que obtuvimos anteriormente en la Pregunta 2.2 e).

15 Actividad Aplicada 2: Intervalo de confianza

Utilizando lo realizado en las preguntas anteriores, responda:

- a. ¿Dentro de qué límites se esperaría que esté el promedio poblacional, con probabilidad (cobertura) de .95? Considerando que si se trabaja con una distribución normal, un intervalo para la media con probabilidad de cobertura de .95, considera que el 95% de los valores están contenidos dentro de ± 1.96 desviaciones estándar con respecto a la media. Esto típicamente se conoce como la *Regla empírica*. Entonces se buscan los valores dados por

$$L_{\text{límites}} = \bar{x} \pm Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

donde $\bar{x}$ es la media muestral, $Z_{\alpha/2}$ es el valor 1.96, σ la desviación estándar poblacional y n el tamaño de la muestra.

- b. Construya ahora un intervalo de confianza al 95% utilizando el promedio de la muestra que le fue asignada. ¿El promedio de edad de la población ($\mu = 42.77$) se encuentra dentro de este intervalo?

Solución

16 Pregunta a

 Ver solución

Para estimar los límites del intervalo, utilizamos un intervalo de confianza del 95%, asumiendo que la distribución de la media muestral puede ser aproximada por una distribución normal. Esta aproximación se justifica mediante el Teorema del Límite Central (TLC). Luego, para la estimación de los límites del intervalo utilizaremos la siguiente expresión:

$$L_{\text{límites}} = \bar{x} \pm Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

donde,

$$\bar{x} = 42.66, \quad Z_{\alpha/2} = 1.96, \quad \sigma = 11.91, \quad n = 30$$

Con esto, se tiene que $\frac{\sigma}{\sqrt{n}} \approx 2.17$. Reemplazando los valores en la expresión anterior, se obtiene:

$$\begin{aligned} L_{\text{límites}} &= 42.66 \pm (1.96 \cdot 2.17) \\ &= 42.66 \pm 4.25 \end{aligned}$$

Por lo tanto, los límites del intervalo quedan:

$$L_{\text{límites}} = [38.41, 46.91]$$

Por lo tanto, con una probabilidad de cobertura del 95%, se espera que el promedio poblacional se encuentre entre 38.41 y 46.91 años.

17 Pregunta b

 Ver solución

Rows: 400

Columns: 7

Groups: grupo [10]

\$ grupo <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~

\$ muestra <chr> "m_1", "m_101", "m_11", "m_111", "m_121", "m_131", "m_1~

\$ stat_mean <dbl> 42.83333, 45.76667, 43.80000, 41.93333, 44.43333, 43.70~

\$ standard_error <dbl> 2.174459, 2.174459, 2.174459, 2.174459, 2.174459, 2.174~

\$ ll <dbl> 38.57139, 41.50473, 39.53806, 37.67139, 40.17139, 39.43~

\$ ul <dbl> 47.09527, 50.02861, 48.06194, 46.19527, 48.69527, 47.96~

\$ status <chr> "yes", "yes", "yes", "yes", "yes", "yes", "yes", "yes", "yes", ~

Aquellas muestras cuyos intervalos de confianza estimados al 95% que no contienen al parámetro poblacional ($\mu = 42.77$) son las siguientes: m_251, m_192, m_282, m_155, m_175, m_235, m_305, m_335, m_316, m_207, m_237, m_278, m_239, m_309, m_290, m_340. Con respecto al total de muestras, esta cantidad equivale al $\frac{16}{400} * 100 = 4\%$, en otras palabras, el 4% de todos los intervalos de confianza estimados no contiene al promedio poblacional.

Para más detalles de los intervalos estimados para estas muestras, puede consultar la siguiente tabla.

grupo	muestra	media_pobla- cional	Intervalo Confianza	status
1	m_251	42.77	[34.238 , 42.762]	No contiene al parametro poblacional
2	m_192	42.77	[33.938 , 42.462]	No contiene al parametro poblacional
2	m_282	42.77	[42.871 , 51.395]	No contiene al parametro poblacional
5	m_155	42.77	[33.671 , 42.195]	No contiene al parametro poblacional
5	m_175	42.77	[44.238 , 52.762]	No contiene al parametro poblacional
5	m_235	42.77	[33.271 , 41.795]	No contiene al parametro poblacional
5	m_305	42.77	[44.171 , 52.695]	No contiene al parametro poblacional

5	m_335	42.77	[43.271 , 51.795]	No contiene al parametro poblacional
6	m_316	42.77	[43.438 , 51.962]	No contiene al parametro poblacional
7	m_207	42.77	[33.571 , 42.095]	No contiene al parametro poblacional
7	m_237	42.77	[43.305 , 51.829]	No contiene al parametro poblacional
8	m_278	42.77	[34.171 , 42.695]	No contiene al parametro poblacional
9	m_239	42.77	[45.471 , 53.995]	No contiene al parametro poblacional
9	m_309	42.77	[44.438 , 52.962]	No contiene al parametro poblacional
10	m_290	42.77	[34.205 , 42.729]	No contiene al parametro poblacional
10	m_340	42.77	[34.071 , 42.595]	No contiene al parametro poblacional

18 Actividad Aplicada 3 (avanzado): Probabilidad de cobertura

Utilizando la distribución de los promedios muestrales, responda:

- Calcule la probabilidad de que la media muestral $\bar{x}$ de los promedios de las edades sea mayor a 48 años. Utilice R para determinarla.
- Si su muestra aleatoria tiene una media muestral de 48 años, ¿consideraría usted que esto es poco común? ¿Qué conclusión podría sacar?

Solución

19 Pregunta a

💡 Ver solución

La probabilidad se calcula como el área bajo la curva normal *estándar* para valores mayores que 48. Primero, transformamos 48 a una puntuación Z :

$$Z = \frac{\bar{x} - \mu_{\bar{x}}}{\sigma_{\bar{x}}}$$

Sustituimos los valores:

$$Z = \frac{48 - 42.66}{2.11} \approx 2.53$$

Ahora, consultamos la tabla de la distribución normal estándar o utilizamos R. Típicamente, para determinar probabilidades acumuladas se usa el comando `pnorm()`. La probabilidad acumulada para $Z = 2.53$ es aproximadamente:

$$P(Z \leq 2.53) \approx 0.994$$

La probabilidad de que $\bar{x}$ sea mayor a 48 es el complemento, dado que el área bajo la curva normal es 1. Entonces tenemos:

$$P(Z > 2.53) = 1 - P(Z \leq 2.53) \approx 1 - 0.994 \approx 0.005$$

Por lo tanto, la probabilidad de que la media muestral sea mayor a 48 años es aproximadamente 0.005 o 0.5%.

En R tenemos:

```
x_barra <- 48 # Valor de la media muestral
mu_x_barra <- 42.66 # Valor del promedio de la distribución de la media muestral
sigma_x_barra <- 2.11 # Valor de la desviación estándar de la distribución de la media muestral

# Calcular la puntuación Z
Z <- (x_barra - mu_x_barra) / sigma_x_barra

# Calcular la probabilidad acumulada para Z con el comando pnorm()
probabilidad_acumulada <- pnorm(Z)

# Calcular la probabilidad de que X barra sea mayor a 48
probabilidad_mayor <- 1 - probabilidad_acumulada

# Mostrar el resultado
probabilidad_mayor
```


20 Pregunta b

 Ver solución

¿Es poco común que la media muestral sea de 48 años? Un evento se considera "poco común" si su probabilidad es muy baja, típicamente menos del 5% ($P < 0.05$). En este caso, la probabilidad de obtener una media muestral mayor a 48 es 0.5%, lo que es sumamente bajo.

Hay evidencia suficiente para considerar que esta media muestral es poco común. Si esta media muestral fuera observada, podríamos cuestionar si es consistente con el promedio poblacional o si hay factores adicionales que están afectando los resultados.