

# Formativa 03: Aplicación Regresión lineal simple

EDU3826

Dany Lopez (dxlopez@ul.cl) - José Luis Pérez (josel.perez@uc.cl)

## Contenido

|                                                                                 |          |
|---------------------------------------------------------------------------------|----------|
| <b>Objetivo</b>                                                                 | <b>2</b> |
| <b>Descripción</b>                                                              | <b>2</b> |
| <b>Contexto Educativo</b>                                                       | <b>3</b> |
| Descripción Caso 1 . . . . .                                                    | 3        |
| Descripción Caso 2 . . . . .                                                    | 3        |
| <b>Abordaje del problema</b>                                                    | <b>3</b> |
| <b>Flujo de trabajo</b>                                                         | <b>4</b> |
| Etapa 0: Elementos previos . . . . .                                            | 4        |
| <b>Caso 1</b>                                                                   | <b>5</b> |
| Etapa 1: Abrir/Crear bases de datos . . . . .                                   | 5        |
| Etapa 2: Inspección de datos y ajuste de modelos . . . . .                      | 5        |
| Etapa 3: Formateo de resultados . . . . .                                       | 7        |
| Etapa 4: Reporte de resultados . . . . .                                        | 8        |
| Interpretación del intercepto ( $\beta_0$ ) y pendiente ( $\beta_1$ ) . . . . . | 9        |
| <b>Caso 2</b>                                                                   | <b>9</b> |
| Etapa 1: Abrir/Crear los datos . . . . .                                        | 9        |
| Etapa 2: Inspección de datos y ajuste de modelos . . . . .                      | 10       |
| Etapa 3: Formateo de resultados . . . . .                                       | 13       |
| Etapa 4: Reporte de resultados . . . . .                                        | 13       |
| Interpretación del intercepto ( $\beta_0$ ) y pendiente ( $\beta_1$ ) . . . . . | 14       |

## Objetivo

- Aplicar modelos de regresión lineal simple
- Comprender los conceptos asociados a los modelos de regresión lineal simple.
- Interpretar los coeficientes de regresión lineal (intercepto y pendiente) situados en contextos educativos.

## Descripción

Sabemos que de manera genérica, un modelo lineal simple queda expresado de la siguiente forma

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

En el que

- $Y$  es la variable dependiente (por ejemplo, rendimiento académico).
- $X$  es la variable independiente (por ejemplo, género).
- $\beta_0$  es el intercepto.
- $\beta_1$  es el coeficiente que expresa la relación lineal entre  $Y$  con  $X$ .
- $\varepsilon$  es el término de error.

Si denotamos por  $\hat{Y} = \beta_0 + \beta_1 X$  al valor predicho por el modelo, entonces la ecuación anterior se puede escribir de la siguiente forma

$$Y = \hat{Y} + \varepsilon.$$

Es decir, existe una desviación o error  $\varepsilon$  en la predicción  $\hat{Y}$  al compararlo con el valor observado  $Y$ .

Con el objetivo de comprender y situar la interpretación de los coeficientes  $\beta_0$  y  $\beta_1$ , vamos a considerar dos casos:

- **El primer caso (Caso 1)**, corresponde a una situación en la que se tiene una *variable independiente numérica* (de razón o intervalo) como predictor de los puntajes de una *variable dependiente también numérica* (de razón o intervalo).
- **El segundo caso (Caso 2)**, corresponde a un problema en el que se tiene una *variable independiente categórica* (por ejemplo nominal o factores) como predictor de los puntajes de una *variable dependiente también numérica* (de razón o intervalo).

Lo anterior se resume en la siguiente tabla, vea que ambos casos involucra  $Y$  medida en una escala numérica.

| Caso   | Variable dependiente ( $Y$ ) | Variable explicativa ( $X$ ) |
|--------|------------------------------|------------------------------|
| Caso 1 | Numérica                     | Numérica                     |
| Caso 2 | Numérica                     | Categorica                   |

Luego, para estos dos casos vamos a interpretar el coeficiente  $\beta_0$  (intercepto) y  $\beta_1$  (pendiente) al ajustar el modelo de regresión lineal. De tal forma, lograremos comprender la relación entre  $Y$  y  $X$ . Partiremos con el caso 1 y para luego abordar del caso 2.

## Contexto Educativo

### Descripción Caso 1

La base de datos utilizada en el Caso 1 proviene de un estudio hipotético (simulación) para explorar la relación que tiene las ausencias escolares de los estudiantes de una escuela secundaria en su rendimiento académico. En este contexto, el *rendimiento académico* se mide en una escala de 0 a 100, y las ausencias se mide como la cantidad total de días que un estudiante no asistió a la escuela durante un semestre.

### Descripción Caso 2

La base de datos utilizada en el Caso 2 proviene de un estudio hipotético para explorar la relación entre género con el rendimiento académico de estudiantes de una escuela secundaria. La motivación detrás de este estudio es comprender si existe una diferencia significativa en el rendimiento académico entre estudiantes mujeres y hombres. En este contexto, el rendimiento académico se mide en una escala de 0 a 100, y el género se mide como una variable binaria (0 para hombres y 1 para mujeres).

## Abordaje del problema

A continuación se encuentra el flujo de trabajo por medio del cual se abordará cada caso.

## Flujo de trabajo

- La gran mayoría de los procedimientos involucrados en análisis de datos involucra ciertas etapas estables que responden a propósitos específicos. En conjunto, estas etapas logran cumplir el propósito general de un problema de investigación.
- Estos pasos son:
  - *Etapas 1: Abrir/Crear los datos*
  - *Etapas 2: Inspección de datos y ajuste de modelos*
  - *Etapas 3: Formateo de resultados*
  - *Etapas 4: Reporte de resultados*

### Etapas 0: Elementos previos

Esta etapa consiste en incluir elementos previos que necesarios para ejecutar códigos en R. Para el presente taller vamos a emplear algunas librerías fundamentales para procesar inicialmente nuestros datos, como la librería readxl, dplyr, tidyr y ggplot2 **Para que los códigos incluidos como guías de este taller funcionen es necesario que las librerías recomendadas sean instaladas primero, una vez que se instalan no se deben volver a instalar.**

Esta librería, la podemos llamar e instalar empleando las siguientes línea de código:

```
#-----  
# instalar librerias  
#-----  
  
#install.packages('readr') # borrar el símbolo # para ejecutar código  
#-----  
# cargar librerias  
#-----  
  
library(readxl)  
library(readr)  
library(ggplot2)  
  
#-----  
# Opciones especiales  
#-----  
  
# Evita la notacion cientifica  
options(scipen=999)
```

## Caso 1

### Etapla 1: Abrir/Crear bases de datos

- Vamos a crear una base de datos en R y la vamos a guardar como un archivo CSV para su posterior análisis. Note que ahora utilizamos la función `data.frame()` para construir nuestra tabla.

```
# Crear la base de datos
data <- data.frame(
  student_id = 1:60,
  absences = c(10, 5, 12, 3, 7, 8, 11, 2, 15, 6, 9, 13, 4, 14, 1, 16, 7, 5, 12, 3, 8, 10, 6, 11, 2, 14,
              9, 13, 4, 1, 15, 8, 7, 12, 3, 5, 11, 6, 10, 14, 9, 13, 4, 2, 8, 15, 7, 12, 6, 10, 5, 11, 3, 14, 1, 9, 15, 8, 4, 7),
  academic_performance = c(75, 88, 70, 92, 85, 78, 72, 95, 60, 80, 76, 65, 90, 62, 98, 58, 83, 86, 68,
                          93, 77, 74, 82, 71, 96, 64, 75, 66, 91, 97, 61, 79, 84, 69, 94, 87, 73, 81,
                          76, 63, 74, 67, 89, 97, 78, 59, 85, 70, 80, 75, 88, 72, 92, 62, 99, 77, 60,
                          79, 90, 83)
)

# Guardar la base de datos en un archivo CSV
readr::write_csv(data, "academic_data.csv")
```


La base de datos ya se creó y guardó. A continuación se muestran los primeros 10 registros.

| student_id | absences | academic_performance |
|------------|----------|----------------------|
| 1          | 10       | 75                   |
| 2          | 5        | 88                   |
| 3          | 12       | 70                   |
| 4          | 3        | 92                   |
| 5          | 7        | 85                   |
| 6          | 8        | 78                   |
| 7          | 11       | 72                   |
| 8          | 2        | 95                   |
| 9          | 15       | 60                   |
| 10         | 6        | 80                   |

### Etapla 2: Inspección de datos y ajuste de modelos

Antes de ajustar nuestro modelo lineal, vamos a inspeccionar los datos. Para ello haremos un gráfico de dispersión que muestre visualmente la relación entre las ausencias y el rendimiento académico.

```
library(ggplot2)
# Crear un gráfico de dispersión con la línea de regresión
ggplot(data, aes(x = absences, y = academic_performance)) +
  geom_point() +
  labs(title = "Relación entre Ausencias y Rendimiento Académico",
       x = "Número de Ausencias",
       y = "Rendimiento Académico")
```



Del gráfico se observa una relación inversa, es decir, en la medida que el Número de ausencias aumenta el Rendimiento académico disminuye. Veamos si esta relación es significativa estadísticamente hablando (recuerde las tres preguntas fundamentales del curso). Para ello, ajustaremos el siguiente modelo lineal

$$\text{Rendimiento Académico} = \beta_0 + \beta_1 \text{Ausencias} + \varepsilon$$

Ajustamos el modelo anterior a los datos.

```
# Ajustar el modelo de regresión lineal
model <- lm(academic_performance ~ absences, data = data)
```

El resultado (*output*) se muestra a continuación usando la función `summary()`:

```
# Resumen del modelo
summary(model)
```

Call:

```
lm(formula = academic_performance ~ absences, data = data)
```

Residuals:

```
   Min     1Q   Median     3Q      Max 
-4.5018 -0.8314  0.1634  1.1616  3.1657
```

Coefficients:

```
      Estimate Std. Error t value Pr(>|t|)    
(Intercept) 100.50642    0.44433  226.20  <2e-16 ***
absences     -2.66744    0.04794  -55.65  <2e-16 ***
---

```

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.569 on 58 degrees of freedom  
Multiple R-squared: 0.9816, Adjusted R-squared: 0.9813  
F-statistic: 3096 on 1 and 58 DF, p-value: < 2.2e-16

### Etapla 3: Formateo de resultados

Podemos mostrar el output de manera más amigable usando la función `tab_model` de la librería `sjPlot`. El *output* se muestra a continuación:

```
sjPlot::tab_model(model, show.se = TRUE, show.stat = TRUE)
```

| academic performance                     |               |            |                |           |                  |
|------------------------------------------|---------------|------------|----------------|-----------|------------------|
| Predictors                               | Estimates     | std. Error | CI             | Statistic | p                |
| (Intercept)                              | 100.51        | 0.44       | 99.62 - 101.40 | 226.20    | <b>&lt;0.001</b> |
| absences                                 | -2.67         | 0.05       | -2.76 - -2.57  | -55.64    | <b>&lt;0.001</b> |
| Observations                             | 60            |            |                |           |                  |
| R <sup>2</sup> / R <sup>2</sup> adjusted | 0.982 / 0.981 |            |                |           |                  |

Usando la información anterior, la ecuación que especifica nuestro modelo lineal queda de la siguiente forma:

$$\text{Rendimiento Academico} = 100.51 - 2.67\text{Ausencias} + \varepsilon$$


Es decir, los puntajes de Rendimiento académico quedan predichos por el siguiente modelo

$$\text{Rendimiento Académico}_{\text{Predicho}} = 100.51 - 2.67\text{Ausencias}$$

A continuación, se muestra en un gráfico de dispersión con la recta ajustada a los datos

```
library(ggplot2)
# Crear un gráfico de dispersión con la regresión
ggplot(data, aes(x = absences, y = academic_performance)) +
  geom_point() +
  geom_smooth(method = "lm", col = "blue") +
  labs(title = "Relación entre Ausencias y Rendimiento Académico",
       x = "Número de Ausencias",
       y = "Rendimiento Académico")
```

`geom\_smooth()` using formula = 'y ~ x'



#### **Etapas 4: Reporte de resultados**

Los resultados indican una relación negativa y estadísticamente significativa entre el número de ausencias a clases durante el semestre y el rendimiento académico de las y los estudiantes,  $F(1, 58) = 3096, p < .01$ . Específicamente, por cada ausencia adicional se

observa una disminución promedio de 2.67 puntos en el rendimiento académico de las y los estudiantes. El modelo presenta un buen ajuste, explicando aproximadamente el 98% de la variabilidad observada en los datos ( $R^2 = 0.982$ ), lo que sugiere una alta capacidad predictiva de la ausencias sobre el rendimiento académico.

#### Nota

-Note que aquí hemos exagerado los efectos de la relación entre ausencia a clases y rendimiento académico.

### Interpretación del intercepto ( $\beta_0$ ) y pendiente ( $\beta_1$ )

- El intercepto  $\beta_0$  es 100.5064, lo que indica que cuando el número de ausencias es cero, el rendimiento académico promedio de los estudiantes es 100.5064 puntos. Recuerde que el intercepto es el valor que toma  $\hat{Y}$  para los casos en que  $X = 0$ .
- El coeficiente de ausencias ( $\beta_1$ , o pendiente) es -2.6674, lo que indica que por cada día de ausencia adicional, el rendimiento académico promedio de los estudiantes disminuye aproximadamente 2.67 puntos. Recuerde que la pendiente expresa la magnitud del cambio en  $Y$  por unidad de cambio en  $X$  (para este caso dado que  $X$  está medido en días, entonces una unidad de cambio en  $X$  significa un día adicional de ausencia a clases durante el primer semestre).
- El valor  $p$  asociado con el coeficiente de ausencias es menor que 0.001, indicando que la relación entre el número de ausencias y el rendimiento académico es estadísticamente significativa.
- El coeficiente de determinación ( $R^2$ ) igual a 0.982 indica que el 98.2% de la variabilidad en el rendimiento académico puede ser explicada por el número de ausencias.

## Caso 2

Ahora vamos a utilizar una variable independiente categórica para comprender cómo interpretar los resultados de una regresión lineal simple.

### Etapas 1: Abrir/Crear los datos

- Vamos a crear la base de datos en R y la vamos a guardar como un archivo CSV para su posterior análisis. Note que ahora utilizamos la función `data.frame()` para construir nuestra tabla.

```
# Crear la base de datos
data_g <- data.frame(
  student_id = 1:60,
  gender = c(rep(1, 30), rep(0, 30)), # 0 para hombres, 1 para mujeres
  academic_performance = c(95, 88, 70, 92, 85, 78, 83, 95, 91, 80, 86, 85, 90, 92, 98, 58,
    83, 86, 78, 93, 77, 94, 82, 81, 96, 94, 75, 66, 91, 97, 61, 79,
    84, 69, 94, 87, 73, 81, 76, 63, 74, 67, 89, 97, 78, 59, 85, 70,
    80, 75, 88, 72, 92, 62, 99, 77, 60, 79, 90, 83)
)

# Guardar la base de datos en un archivo CSV
readr::write_csv(data_g, "academic_data_gender.csv")
```

La base de datos ya se creó y guardó. A continuación se muestran los primeros 10 registros.

|    | student_id | gender | academic_performance |
|----|------------|--------|----------------------|
| 1  | 1          | 1      | 95                   |
| 2  | 2          | 1      | 88                   |
| 3  | 3          | 1      | 70                   |
| 4  | 4          | 1      | 92                   |
| 5  | 5          | 1      | 85                   |
| 40 | 40         | 0      | 63                   |
| 41 | 41         | 0      | 74                   |
| 42 | 42         | 0      | 67                   |
| 43 | 43         | 0      | 89                   |
| 44 | 44         | 0      | 97                   |

## Etapa 2: Inspección de datos y ajuste de modelos

Antes de ajustar nuestro modelo lineal, vamos a inspeccionar los datos. Para ello haremos estadística descriptiva y un gráfico *boxplot* para explorar visualmente la relación entre el género y el rendimiento académico. Note que debido a que nuestra variable independiente  $X$  es el género, se requiere una categoría para expresar a las mujeres y hombres. En este caso, esta variable se encuentra codificada con un 0 para identificar a los hombres y con un 1 para identificar a las mujeres).


Para el análisis descriptivo, se emplearon la media y la desviación estándar del rendimiento académico según género. Los resultados, presentados a continuación, muestran que las mujeres obtuvieron un puntaje promedio más alto ( $M = 85.3$ ,  $DE = 9.65$ ) en comparación con los hombres ( $M = 78.1$ ,  $DE = 11.20$ ).

```
data_g %>%
  dplyr::group_by(gender) %>%
  dplyr::summarise(
    academic_performance_mean = mean(academic_performance, na.rm = T),
    academic_performance_SD = sd(academic_performance, na.rm = T)
  )
```

| gender | academic_performance_mean | academic_performance_SD |
|--------|---------------------------|-------------------------|
| 0      | 78.1                      | 11.198368               |
| 1      | 85.3                      | 9.645975                |

El gráfico *boxplot*, muestra

```
library(ggplot2)
# Crear un gráfico de dispersión con la línea de regresión
ggplot(data_g, aes(x = factor(gender), y = academic_performance)) +
  geom_boxplot() +
  labs(title = "Relación entre Género y Rendimiento Académico",
       x = "Género (0 = Hombre, 1 = Mujer)",
       y = "Rendimiento Académico")
```



Ambas fuentes de evidencia indican que existe una relación entre el género y el rendimiento académico, es decir, que el rendimiento académico promedio es diferente

entre hombres y mujeres. Pongamos a prueba esta hipótesis ajustando el siguiente modelo lineal

$$\text{Rendimiento Academico} = \beta_0 + \beta_1 \text{Genero} + \varepsilon$$

**i** Nota

-Note que este tipo de situación ya la hemos abordado anteriormente, pero por medio de una prueba  $t$ . Más adelante se verá que por medio de un modelo de regresión lineal es posible recuperar los resultados de una prueba  $t$ .

Ajustamos el modelo anterior a los datos contruidos. El resultado (*ouput*) se muestra a continuación usando la función `summary()`:

```
# Ajustar el modelo de regresión lineal
model_g <- lm(academic_performance ~ gender, data = data_g)

# Resumen del modelo
summary(model_g)
```

Call:

```
lm(formula = academic_performance ~ gender, data = data_g)
```

Residuals:

| Min    | 1Q    | Median | 3Q   | Max   |
|--------|-------|--------|------|-------|
| -27.30 | -6.40 | 0.70   | 7.95 | 20.90 |

Coefficients:

|             | Estimate | Std. Error | t value | Pr(> t )    |
|-------------|----------|------------|---------|-------------|
| (Intercept) | 78.100   | 1.908      | 40.931  | < 2e-16 *** |
| gender      | 7.200    | 2.698      | 2.668   | 0.00987 **  |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.45 on 58 degrees of freedom

Multiple R-squared: 0.1093, Adjusted R-squared: 0.09397

F-statistic: 7.119 on 1 and 58 DF, p-value: 0.009871

### Etapa 3: Formateo de resultados

Podemos mostrar el output de manera más amigable usando la función `tab_model` de la librería `sjPlot`. El *output* se muestra a continuación:

```
sjPlot::tab_model(model_g, show.se = TRUE, show.stat = TRUE)
```

| academic performance                     |               |            |               |           |                  |
|------------------------------------------|---------------|------------|---------------|-----------|------------------|
| Predictors                               | Estimates     | std. Error | CI            | Statistic | p                |
| (Intercept)                              | 78.10         | 1.91       | 74.28 - 81.92 | 40.93     | <b>&lt;0.001</b> |
| gender                                   | 7.20          | 2.70       | 1.80 - 12.60  | 2.67      | <b>0.010</b>     |
| Observations                             | 60            |            |               |           |                  |
| R <sup>2</sup> / R <sup>2</sup> adjusted | 0.109 / 0.094 |            |               |           |                  |

Usando la información anterior, la ecuación que especifica nuestro modelo lineal queda de la siguiente forma:

$$\text{Rendimiento Academico} = 78.10 + 7.2\text{Genero} + \varepsilon$$

Es decir, los puntajes de Rendimiento academico quedan predichos por el siguiente modelo

$$\text{Rendimiento Academico}_{\text{Predicho}} = 78.10 + 7.2\text{Genero}$$

### Etapa 4: Reporte de resultados

Se observa una relación positiva y estadísticamente significativa entre el género y el rendimiento académico,  $F(1, 58) = 7.119$ ,  $p < .01$ . En promedio, las mujeres presentan un rendimiento académico 7.20 puntos superior al de los hombres ( $B_1 = 7.20$ ,  $p < .01$ ). Este efecto del género explica aproximadamente un 10.9% de la variabilidad en el rendimiento académico ( $R^2 = 0.109$ ).

#### Nota

-Note que aquí hemos exagerado los efectos de la relación entre Género y rendimiento académico.

## Interpretación del intercepto ( $\beta_0$ ) y pendiente ( $\beta_1$ )

- El intercepto  $\beta_0$  es 78.10, lo que indica que cuando el Género es cero, el rendimiento académico promedio de los estudiantes es 78.10 puntos. Seguramente ya notó que decir *cuando el Género es cero* no tiene mucho sentido ¿Qué significa *cuando Género es cero*?. Para responder esto, tenemos que ir al inicio y recordar cómo está codificada la variable Género (cuál fue la categoría que está codificada con el valor 0). Luego de revisar, vemos que el 0 fue asignado para representar a los *hombres* y 1 para representar a las mujeres. Por lo tanto, la forma adecuada de interpretar el coeficiente  $\beta_0 = 78.10$  sería: El intercepto  $\beta_0 = 78.10$  indica el rendimiento académico promedio que obtienen los hombres (es decir, cuando *Género* = 0). Notemos que este intercepto coincide con el promedio que obtuvimos para los hombres cuando hicimos estadística descriptiva ( $M = 78.1, DS = 11.20$ ). En otras palabras, dada la codificación de la variable Género, a partir del intercepto podemos recuperar el promedio del rendimiento académico para los hombres.
- El coeficiente  $\beta_1$  o pendiente es +7.2, lo que indica una relación positiva (y ya vimos que significativa) entre el género y el rendimiento académico. Una interpretación más sustantiva de este coeficiente indica que las mujeres (codificada por 1) en promedio tienen un rendimiento académico 7.2 puntos más alto que los hombres. Al realizar esta comparación, -es decir el promedio de las mujeres en comparación con el promedio de los hombres-, se está expresando la unidad de cambio en la variable independiente (categoría 1 en comparación con la categoría 0) para expresar el cambio en la variable dependiente.
- Note que si utilizamos el modelo dado por  $\text{Rendimiento Académico}_{\text{Predicho}} = 78.10 + 7.2\text{Género}$  y reemplazamos *Género* = 1, es decir, consideramos a las mujeres, el valor que toma  $\text{Rendimiento Académico}_{\text{Predicho}}$  es

$$\text{Rendimiento Académico}_{\text{Predicho}} = 78.10 + 7.2\text{Género}$$

$$\text{Rendimiento Académico}_{\text{Predicho}} = 78.10 + 7.2(1)$$

$$\text{Rendimiento Académico}_{\text{Predicho}} = 78.10 + 7.2 = 85.3$$

que corresponde al puntaje promedio de rendimiento académico que observamos para las mujeres cuando hicimos estadística descriptiva ( $M = 85.3, DS = 9.65$ ).

- El valor  $p$  asociado con el coeficiente de ausencias es menor que 0.01, indicando que la relación entre Género y el rendimiento académico es estadísticamente significativa.
- El coeficiente de determinación ( $R^2$ ) de 0.109 indica que el 10.9% de la variabilidad en el rendimiento académico puede ser explicada por el Género.

## Ejemplo de Reportes: Publicaciones

### Artículos de investigación que reportan evidencia de regresión lineal simple

- Treviño, E., Scheele, J., & Flores, S. M. (2014). Beyond the test score: A mixed methods analysis of a college access intervention in Chile. *Journal of Mixed Methods Research*, 8(3), 255–265. <https://doi.org/10.1177/1558689814527940>

*Article*

# **Beyond the Test Score: A Mixed Methods Analysis of a College Access Intervention in Chile**

Journal of Mixed Methods Research  
2014, Vol. 8(3) 255–265  
© The Author(s) 2014  
Reprints and permissions:  
[sagepub.com/journalsPermissions.nav](http://sagepub.com/journalsPermissions.nav)  
DOI: 10.1177/1558689814527940  
[mmr.sagepub.com](http://mmr.sagepub.com)  


**Ernesto Treviño<sup>1</sup>, Judith Scheele<sup>1</sup>, and  
Stella M. Flores<sup>2</sup>**

Figure 1: Página cortada.

**Table 1.** Linear Regressions Comparing the GPA of Students From the *Propedéutico* Program and Students Accessing the University via the Regular Process, at the End of High School and at the End of the First Year of University, 2010.

| Dependent variable =<br>Standardized GPA | Model for the end<br>of high school<br>(n = 183) | Model for the end of the<br>first year of<br>university (n = 74) |
|------------------------------------------|--------------------------------------------------|------------------------------------------------------------------|
| Independent variable                     |                                                  |                                                                  |
| <i>Propedéutico</i>                      | −0.170***                                        | −0.577***                                                        |
| R <sup>2</sup>                           | 0.03                                             | 0.33                                                             |

\*p < 0.05, \*\*p < 0.01, \*\*\*p < 0.001.

Source: Centro de Políticas Comparadas de Educación (CPCE).

### Quantitative Results: Achievement Gap

The results of the regression analyses show that, at the end of high school, students in the *Propedéutico* program showed lower achievement than their counterparts who applied to the same university through the regular admission system. *Propedéutico* students' GPA was on average 0.17 standard deviations lower than that of their peers, a statistically significant difference, although it is only a 0.05-point difference on the Chilean grade scale (Table 1).

Statistical tests comparing the two groups' GPAs show the achievement gap increased in college, reaching 0.58 standard deviations after two semesters, which means that the regular admission students' GPA averaged 0.32 points higher than their peers' (6.19 vs. 5.87). However, all *Propedéutico* students in the sample were able to meet the university's academic requirements despite having lower grades than the students from more advantageous backgrounds".

Figure 2: Extracto de reporte de resultados.

- Ellis, R. A., Han, F., & Pardo A. (2017). Improving Learning Analytics - Combining Observational and Self-Report Data on Student Learning. *Educational Technology & Society*, 20 (3), 158-169. <https://www.jstor.org/stable/26196127>

## **Improving Learning Analytics – Combining Observational and Self-Report Data on Student Learning**

**Robert A. Ellis<sup>1\*</sup>, Feifei Han<sup>1</sup> and Abelardo Pardo<sup>2</sup>**

<sup>1</sup>Centre for Research on Learning and Innovation, Faculty of Education and Social Work, University of Sydney, Australia // <sup>2</sup>School of Electrical Engineering, Faculty of Engineering and Information Technologies, University of Sydney, Australia // Robert.Ellis@sydney.edu.au // Feifei.Han@sydney.edu.au // Abelardo.Pardo@sydney.edu.au

\*Corresponding author

(Submitted February 29, 2016; Revised July 27, 2016; Accepted September 13, 2016)

### **ABSTRACT**

The field of education technology is embracing a use of learning analytics to improve student experiences of learning. Along with exponential growth in this area is an increasing concern of the interpretability of the analytics from the student experience and what they can tell us about learning. This study offers a way to

Figure 3: Página portada.

variable also shows a pattern consistent with the self-report and observational data. There is a significant difference between the score of the students in the deep cluster (mean = 0.53) and the surface cluster (mean = -0.23). The main conclusion from this result is that both self-report and observational variables are important when identifying the relations with the overall academic performance.

#### Multiple regression analysis

The results of the third stage of analyses compare two linear models of multiple regression to see the effect of combining the self-report and observational variables that had significant correlation with the final score (see Table 5).

Table 5. Results of multiple regression analysis

| Variables      | B     | SE B | $\beta$ | t     | Adjusted R <sup>2</sup> | p   | f <sup>2</sup> |
|----------------|-------|------|---------|-------|-------------------------|-----|----------------|
| <b>Model 1</b> |       |      |         |       | .09                     | .00 | .10            |
| Surface        | -0.31 | .08  | -.31**  | -3.84 |                         |     |                |
| <b>Model 2</b> |       |      |         |       | .34                     | .00 | .52            |
| Surface        | -0.29 | .07  | -.29**  | -4.16 |                         |     |                |
| Dashboard      | 0.03  | .08  | .03     | 0.31  |                         | .75 |                |
| Col-Exp        | -0.34 | .19  | -.34    | -1.84 |                         | .07 |                |
| Resource       | 0.88  | .21  | .88**   | 4.28  |                         | .00 |                |
| MCQ            | 0.29  | .12  | .29*    | 2.40  |                         | .02 |                |
| Exercise       | -0.26 | .18  | -.26    | -1.40 |                         | .16 |                |

Notes. \*\* $p < .01$ ; \* $p < .05$ . Surface = surface approaches to study, Col-Exp = collapse and expand, MCQ = multiple choice questions.

Before performing the multiple regression analysis, a series of tests were conducted to examine the assumptions that may affect its reliability. The initial analysis of standard residuals confirmed the absence of outliers (Std. Residual Min = -2.15, Std. Residual Max = 2.54). The tolerance values were above 0.10 for all the variables confirming the absence of multicollinearity. Finally, the Durbin-Watson statistic verified the absence of autocorrelation (Durbin-Watson = 2.08).

Model 1 included only the self-reported surface approach to learning whereas model 2 was obtained with the self-report variable and the five observational variables which have significant correlations with the final score. The results for both models are shown in **Error! Reference source not found.** Model one reveals that the surface approach to study contributed significantly to the regression model:  $F(1, 143) = 14.72, p < .01, f^2 = .10$ . However, the model accounted for only 9% of the variation in the final marks. Model 2 also returned a significant result:  $F(5, 138) = 10.76, p < .01, f^2 = .52$ , however in this case, the model accounts for 34% of the variation. This means an additional 25% of variation in students' academic performance is explained when the observational variables are included in the model. The increase in  $R^2$  also means that the prediction intervals obtained with the model using all six variables (self-report and observational) will be significantly smaller.

A more detailed analysis of this result shows that three independent variables significantly predicted students' academic performance: the surface approach to study ( $\beta = -.29, p < .01$ ), the number of times an online resource was accessed ( $\beta = .88, p < .01$ ), and the number of multiple-choice questions answered ( $\beta = .29, p < .05$ ). The remaining variables, Dashboard, Col-Exp, and Exercises did not make significant predictions to the final course marks. These results show that the combination of self-report and observational data provides a better predictive model of students' learning outcomes.

#### Discussion

Figure 4: Extracto de reporte de resultados. Mirar resultados del Model 1.