

Formativa 04: Aplicación Regresión lineal Múltiple

EDU3826

Dany Lopez (dxlopez@ul.cl) - José Luis Pérez (josel.perez@uc.cl)

Contenido

Objetivo	1
Descripción	2
Contexto Educativo	2
Descripción	2
Abordaje del problema	3
Flujo de trabajo	4
Etapa 0: Elementos previos	4
Etapa 1: Lectura de de datos	5
Etapa 2: Inspección de datos y ajuste de modelos	5
Análisis de correlación	7
Ajuste modelo regresión lineal múltiple	9
Etapa 3: Formateo de resultados	10
Etapa 4: Reporte de resultados	11
Interpretación de los resultados	11
Ejemplo de Reportes: Publicaciones	12
Artículos de investigación que reportan evidencia de regresión lineal múltiple . .	12

Objetivo

- Aplicar modelos de regresión lineal múltiple para responder a preguntas de investigación

- Interpretar los coeficientes ajustado de un modelo de regresión lineal múltiple

Descripción

Sabemos que de manera genérica, un modelo de regresión lineal múltiple queda expresado de la siguiente forma

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{k-1} X_{k-1} + \beta_k X_k + \varepsilon.$$

En el que

- Y es la variable dependiente (por ejemplo, rendimiento académico).
- X_j es la variable independiente j . De manera general, en el modelo se encuentran k variables independientes.
- β_0 es el intercepto (constante).
- β_j es el coeficiente de la variable independiente X_j (pendiente).
- ε es el término de error.

Si denotamos por $\hat{Y} = \beta_0 + (\sum \beta_j X_j)$ al valor predicho por el modelo, entonces la ecuación anterior se puede escribir como

$$Y = \hat{Y} + \varepsilon.$$

Es decir, existe una desviación o error ε en la predicción $\hat{Y}$ al compararlo con el valor observado Y .

Con el objetivo de comprender y situar la interpretación de los coeficientes en regresiones que incluyan más de una variable independiente, a continuación se describe el contexto educativo.

Contexto Educativo

Descripción

Los datos utilizados provienen de un estudio cuyo objetivo fue analizar la relación entre el conocimiento disciplinar, las habilidades de análisis de datos experimentales y la calidad de los informes de laboratorio elaborados por estudiantes de primer año de universidad. La motivación central de esta investigación radica en comprender de qué manera el conocimiento disciplinar y las habilidades de análisis de datos contribuyen a explicar la calidad de dichos informes. Abordar este fenómeno permite generar evidencia empírica para orientar decisiones pedagógicas contextualizadas que reconozcan la escritura como

una competencia fundamental en la formación científica universitaria, sobre todo en el contexto de la formación experimental.

El conocimiento disciplinar (X_1) se evaluó mediante un instrumento compuesto por 26 ítems de selección múltiple centrados en contenidos de mecánica. Los puntajes estimados usando Teoría Clásica de Test, es decir, como la suma del total de preguntas contestadas correctamente. De manera análoga, la habilidad para analizar e interpretar datos experimentales (X_2) se midió utilizando 5 ítems por medio de Teoría Clásica de Test. En cuanto a la variable dependiente, la calidad de los informes de laboratorio (Y) se evaluó en una escala continua de 1 a 100 puntos, utilizando puntajes derivados de un modelo de Crédito Parcial. Esta medición se basó en un mapa de constructo; sin embargo, en el presente análisis se trabajará únicamente con los puntajes continuos, y no con los niveles de desempeño cualitativos asociados. En términos generales, un puntaje de 100 en esta escala indica un informe que evidencia una alta consistencia e integración de lenguajes verbal, visual y matemático, construye conocimiento físico alineado con modelos científicos, y comunica críticamente la relación entre la evidencia empírica y los marcos conceptuales que la sustentan.

Abordaje del problema

Observemos que el fenómeno anterior se puede abordar por medio de las tres preguntas fundamentales del curso:

- ¿Están relacionadas dos variables?
- ¿Cuál es la dirección de la relación entre dos variables?
- ¿Cuál es la fuerza de la relación entre dos variables?

La primera pregunta la responderemos realizando una inspección visual a los datos

Nota

- Notemos que Vik (2014) responde a la primera pregunta por medio de un análisis de varianza entre un modelo nulo y un modelo aumentado. En esta actividad no haremos este ejercicio ya que el foco está en la interpretación de los coeficientes estimados en un modelo de regresión lineal múltiple.

La segunda y tercera pregunta se responderá por medio de un modelo de regresión lineal múltiple, y de manera complementaria, por medio de un análisis de correlaciones.

Nota

- Con el propósito de ofrecer una perspectiva más abarcadora, esta actividad formativa incorpora análisis de correlación. No obstante, dichos análisis no se abordan en profundidad, ya que el foco principal se encuentra en la interpretación de los coeficientes estimados en un modelo de regresión lineal múltiple.

A continuación se encuentra el flujo de trabajo por medio del cual se responderá a las tres preguntas.

Flujo de trabajo

- La gran mayoría de los procedimientos involucrados en análisis de datos involucra ciertas etapas estables que responden a propósitos específicos. En conjunto, estas etapas logran cumplir el propósito general de un problema de investigación.
- Estos pasos son:
 - *Etapas 1: Abrir/Crear los datos*
 - *Etapas 2: Inspección de datos y ajuste de modelos*
 - *Etapas 3: Formateo de resultados*
 - *Etapas 4: Reporte de resultados*
- Para el caso específico en que queramos usar R, debemos agregar una etapa previa a las anteriores, *cargar librerías*. Llamaremos a esta etapa **Etapas 0**. Partiremos describiendo esta etapa para luego explorar las siguientes.

Etapas 0: Elementos previos

Esta etapa consiste en incluir elementos previos que necesarios para ejecutar códigos en R. Para el presente taller vamos a emplear algunas librerías fundamentales para procesar inicialmente nuestros datos, como la librería GGally y ggplot2 **Para que los códigos incluidos como guías de este taller funcionen es necesario que las librerías recomendadas sean instaladas primero, una vez que se instalan no se deben volver a instalar.**

Estas librerías, las podemos llamar e instalar empleando las siguientes línea de código:

```
#-----  
# instalar librerías  
#-----
```

```
#install.packages('ggplot2') # borrar el símbolo # para ejecutar código

#-----
# cargar librerias
#-----

library(ggplot2)
library(GGally)

#-----
# Opciones especiales
#-----

# Evita la notacion cientifica
options(scipen=999)
```

Etapa 1: Lectura de de datos

- Vamos leer los datos que se encuentran en formato csv.

```
# Crear la base de datos
data <- read.csv2("./DDBB/report_data.csv", sep=";", dec=".")
```

A continuación se muestran los primeros 10 registros.

id_student	quality_report	knowledge	skill_data
1	60.16073	5	1
2	77.09004	8	2
3	25.34612	5	1
4	69.82884	11	3
5	40.13053	13	3
6	56.29878	9	0
7	84.79144	11	1
8	45.50363	15	3
9	65.57903	13	4
10	64.47172	24	4


Etapa 2: Inspección de datos y ajuste de modelos

Antes de ajustar nuestro modelo lineal múltiple, vamos a inspeccionar los datos. Para ello haremos un gráfico de dispersión que muestre visualmente la relación entre:


- El conocimiento en Mecánica de las y los estudiantes con la calidad de los reportes que escriben
- La habilidad para analizar datos de las y los estudiantes con la calidad de los reportes que escriben

A continuación se muestran los resultados

```
library(ggplot2)
# Crear un gráfico de dispersión con la línea de regresión
ggplot(data, aes(x = knowledge , y = quality_report)) +
  geom_point() +
  labs(title = "Relación entre Puntajes sobre conocimiento en Mecánica y Calidad de Informes",
        x = "Puntajes conocimiento sobre Mecánica",
        y = "Calidad de Informes")
```



```
ggplot(data, aes(x = skill_data, y = quality_report)) +
  geom_point() +
  labs(title = "Relación entre Análisis de Datos y Calidad de Informes",
        x = "Puntajes en Análisis de Datos",
        y = "Calidad de Informes")
```



En ambos gráficos se aprecia una relación positiva. Por una parte, a medida que aumentan los puntajes de conocimiento disciplinar, también aumenta la calidad de los informes que escriben las y los estudiantes. De manera similar, se observa que un mayor puntaje en la habilidad para analizar e interpretar datos experimentales se asocia con una mejor calidad en los informes. A continuación, examinaremos si estas relaciones son estadísticamente significativas por medio de un análisis de correlaciones (ver nota abajo sobre este tipo de análisis).

i Nota


- Como paso previo al ajuste de un modelo de regresión lineal múltiple, es habitual realizar un análisis bivariado entre las variables mediante coeficientes de correlación. Tal como se comentó en clases, una correlación es equivalente a un modelo de regresión lineal simple. Esta evidencia preliminar servirá como base para ajustar un modelo de regresión lineal múltiple, que permita incorporar de manera simultánea los efectos de diversas variables explicativas.

Análisis de correlación

A continuación se muestran los resultados del análisis de correlaciones. En este caso, dado que las tres variables de interés son medidas con puntajes continuos, utilizamos la correlación tipo pearson.

```
# Cargar librería para análisis de correlación
library(GGally)

# Visualizar la matriz de correlación
ggpairs(data, columns = 2:4, title = "Matriz de Correlación de Variables")
```



La matriz de correlación se muestra a continuación

Warning: package 'tidyr' was built under R version 4.2.3

	knowledge	skill_data	quality_report
knowledge	1.000		
skill_data	0.185*	1.000	
quality_report	0.214*	0.164	1.000

La correlación entre los puntajes de conocimiento en mecánica y la calidad de los informes de laboratorio es positiva aunque débil ($r(141) = .214, p < .05$). De manera similar, se observa una correlación positiva y débil entre el conocimiento disciplinar en mecánica con la habilidad de los estudiantes para analizar e interpretar datos ($r(141) = .185, p < .005$). Finalmente, la correlación entre los puntajes de habilidades para analizar e interpretar datos con los puntajes de calidad de los informes de laboratorio es positiva, débil aunque no estadísticamente significativa ($r(141) = .164, p = .052$).

Nota

- Correlación nula: $0.00 < |r| < 0.10$
- Correlación débil: $0.10 < |r| < 0.30$
- Correlación moderada: $0.30 < |r| < 0.50$
- Correlación fuerte: $0.50 < |r| < 1.00$

Ajuste modelo regresión lineal múltiple

Ahora ajustaremos el siguiente modelo lineal para comprender los efectos que tiene el conocimiento disciplinar y habilidades de datos en la calidad del informe. Para ello, especificamos el siguiente modelo:

$$\text{Calidad Informe} = \beta_0 + \beta_1 \text{Knowledge} + \beta_2 \text{Skill Data} + \varepsilon$$

Ajustamos el modelo anterior a los datos. El resultado (*output*) usando la función `summary()` se muestra a continuación:

```
# Ajustar el modelo de regresión lineal
model <- lm(quality_report ~ knowledge + skill_data, data = data)
# Resumen del modelo
summary(model)
```

Call:

```
lm(formula = quality_report ~ knowledge + skill_data, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-53.794	-9.958	2.329	12.222	36.550

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	43.2857	5.4479	7.945	6.14e-13 ***
knowledge	1.0715	0.4722	2.269	0.0248 *
skill_data	1.6755	1.0942	1.531	0.1280

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 17.08 on 138 degrees of freedom
Multiple R-squared: 0.06181, Adjusted R-squared: 0.04821
F-statistic: 4.546 on 2 and 138 DF, p-value: 0.01225

Table 1: Modelo de regresión lineal

Predictores	B	SE	t	p
Intercepto	43.29	5.448	7.95	<0.001
Knowledge	1.07	0.472	2.27	0.025
Skill Data	1.68	1.094	1.53	0.128

Etapa 3: Formateo de resultados

Podemos mostrar el output de manera más amigable a continuación

```
#sjPlot::tab_model(model,show.se = TRUE, show.stat = TRUE)
library(knitr)
library(xtable)
library(broom)

lm(quality_report ~ knowledge+ skill_data , data = data) %>%
tidy() %>%
  mutate(
    p.value = scales::pvalue(p.value),
    term = c("Intercepto", "Knowledge", "Skill Data")
  ) %>%
kable(col.names = c("Predictores", "B", "SE", "t", "p"),
      digits = c(0, 2, 3, 2, 3),
      align = c("l", "r", "r", "r", "r"),
      booktabs=TRUE,
      caption = "Modelo de regresión lineal"
    ) %>%
# kableExtra::row_spec(., 0, extra_css = "border-top: 1px solid") %>%
kableExtra::row_spec(., 0, extra_css = "border-top: 1px solid") %>%
kableExtra::row_spec(., 1, extra_css = "border-top: 1px solid") %>%
kableExtra::row_spec(., 3, extra_css = "border-bottom: 1px solid")
```

Con los resultados, el modelo de regresión múltiple con dos covariables queda de la siguiente forma

$$\text{Calidad Informe} = 43.29 + 1.07 \text{ Knowledge} + 1.68 \text{ Skill Data} + \varepsilon$$

Etapla 4: Reporte de resultados

Se observa una relación positiva y estadísticamente significativa entre las variables predictoras y la calidad de los informes de laboratorio, $F(2, 138) = 4.55, p < .05$. En particular, los puntajes en la prueba de conocimiento disciplinar predicen significativamente la calidad de los informes, $\beta_1 = 1.07, p < .05$. En contraste, el efecto de la habilidad para analizar e interpretar datos no fue estadísticamente significativo, $\beta_2 = 1.68, p = .128$. El modelo explica aproximadamente el 5% de la variabilidad en la calidad de los informes ($R^2 = 0.048$).

Interpretación de los resultados

Se estimó un modelo de regresión lineal múltiple para explicar los puntajes de calidad de informes de laboratorio, utilizando como variables predictoras los puntajes obtenidos en una prueba de conocimiento disciplinar en mecánica y en una prueba de habilidad para analizar e interpretar datos experimentales. El modelo resultó estadísticamente significativo, $F(2, 138) = 4.55, p = .012$, con un coeficiente de determinación ajustado $R^2 = 0.048$, lo que indica que aproximadamente el 5% de la variabilidad en la calidad de los informes puede ser explicada por estas dos variables.

- El intercepto ($\beta_0 = 43.29$) representa el valor esperado de la calidad del informe cuando ambos puntajes (conocimiento y habilidad) son igual a cero. En una escala de 0 a 100 puntos, este valor sugiere que un estudiante que no obtiene puntaje en ninguna de las pruebas tendría una calidad de informe estimada en aproximadamente 43.29 puntos.
- El coeficiente asociado al conocimiento disciplinar ($\beta_1 = 1.07, p < .05$) indica una relación positiva y estadísticamente significativa entre esta variable y la calidad de los informes. En promedio, un aumento de un punto en el puntaje de conocimiento disciplinar se asocia con un incremento de 1.07 puntos en la calidad del informe, manteniendo constante el puntaje en habilidad para analizar e interpretar datos.
- El coeficiente asociado a la habilidad para analizar e interpretar datos ($\beta_2 = 1.68, p = .128$) indica que, al mantener constante el conocimiento disciplinar, un aumento de un punto en dicha habilidad se asocia con un incremento promedio de 1.68 puntos en la calidad del informe. No obstante, este efecto no es estadísticamente significativo, por lo que no se puede rechazar la hipótesis nula ($H_0 : \beta_2 = 0$).
- El coeficiente de determinación (R^2) de 0.048 indica que aproximadamente un 5% de la variabilidad en la calidad puede ser explicada por el modelo propuesto.

Ejemplo de Reportes: Publicaciones

Artículos de investigación que reportan evidencia de regresión lineal múltiple

- Ellis, R. A., Han, F., & Pardo A. (2017). Improving Learning Analytics – Combining Observational and Self-Report Data on Student Learning. *Educational Technology & Society*, 20 (3), 158–169. <https://www.jstor.org/stable/26196127>

Ellis, R. A., Han, F., & Pardo A. (2017). Improving Learning Analytics – Combining Observational and Self-Report Data on Student Learning. *Educational Technology & Society*, 20 (3), 158–169.

Improving Learning Analytics – Combining Observational and Self-Report Data on Student Learning

Robert A. Ellis^{1*}, Feifei Han¹ and Abelardo Pardo²

¹Centre for Research on Learning and Innovation, Faculty of Education and Social Work, University of Sydney, Australia // ²School of Electrical Engineering, Faculty of Engineering and Information Technologies, University of Sydney, Australia // Robert.Ellis@sydney.edu.au // Feifei.Han@sydney.edu.au // Abelardo.Pardo@sydney.edu.au

*Corresponding author

(Submitted February 29, 2016; Revised July 27, 2016; Accepted September 13, 2016)

ABSTRACT

The field of education technology is embracing a use of learning analytics to improve student experiences of learning. Along with exponential growth in this area is an increasing concern of the interpretability of the analytics from the student experience and what they can tell us about learning. This study offers a way to

Figure 1: Página portada.

variable also shows a pattern consistent with the self-report and observational data. There is a significant difference between the score of the students in the deep cluster (mean = 0.53) and the surface cluster (mean = -0.23). The main conclusion from this result is that both self-report and observational variables are important when identifying the relations with the overall academic performance.

Multiple regression analysis

The results of the third stage of analyses compare two linear models of multiple regression to see the effect of combining the self-report and observational variables that had significant correlation with the final score (see Table 5).

Table 5. Results of multiple regression analysis

Variables	B	SE B	β	t	Adjusted R ²	p	f ²
Model 1					.09	.00	.10
Surface	-0.31	.08	-.31**	-3.84			
Model 2					.34	.00	.52
Surface	-0.29	.07	-.29**	-4.16			
Dashboard	0.03	.08	.03	0.31		.75	
Col-Exp	-0.34	.19	-.34	-1.84		.07	
Resource	0.88	.21	.88**	4.28		.00	
MCQ	0.29	.12	.29*	2.40		.02	
Exercise	-0.26	.18	-.26	-1.40		.16	

Notes. ** $p < .01$; * $p < .05$. Surface = surface approaches to study, Col-Exp = collapse and expand, MCQ = multiple choice questions.

Before performing the multiple regression analysis, a series of tests were conducted to examine the assumptions that may affect its reliability. The initial analysis of standard residuals confirmed the absence of outliers (Std. Residual Min = -2.15, Std. Residual Max = 2.54). The tolerance values were above 0.10 for all the variables confirming the absence of multicollinearity. Finally, the Durbin-Watson statistic verified the absence of autocorrelation (Durbin-Watson = 2.08).

Model 1 included only the self-reported surface approach to learning whereas model 2 was obtained with the self-report variable and the five observational variables which have significant correlations with the final score. The results for both models are shown in **Error! Reference source not found.** Model one reveals that the surface approach to study contributed significantly to the regression model: $F(1, 143) = 14.72, p < .01, f^2 = .10$. However, the model accounted for only 9% of the variation in the final marks. Model 2 also returned a significant result: $F(5, 138) = 10.76, p < .01, f^2 = .52$, however in this case, the model accounts for 34% of the variation. This means an additional 25% of variation in students' academic performance is explained when the observational variables are included in the model. The increase in R^2 also means that the prediction intervals obtained with the model using all six variables (self-report and observational) will be significantly smaller.

A more detailed analysis of this result shows that three independent variables significantly predicted students' academic performance: the surface approach to study ($\beta = -.29, p < .01$), the number of times an online resource was accessed ($\beta = .88, p < .01$), and the number of multiple-choice questions answered ($\beta = .29, p < .05$). The remaining variables, Dashboard, Col-Exp, and Exercises did not make significant predictions to the final course marks. These results show that the combination of self-report and observational data provides a better predictive model of students' learning outcomes.

Discussion

Figure 2: Extracto de reporte de resultados.